

实验数据集越大，实验数据质量越高，数据库课程实验的效果就越好，就越能激发学生利用数据库知识探索实验数据奥秘的主动性和积极性，从而进一步提升数据库课程实验的总体教学效果。

实验数据需要根据所选择或者所设计的数据库模式来进行准备。实验数据准备有三种方式：

① 利用现有数据集作为实验数据集。

② 收集和整理各种来源的数据以生成真实的实验数据集。例如，从 Web 上抓取相关行业或领域的数据，分析整理后生成一个真实的数据集。

③ 利用数据库模拟数据生成工具，生成模拟的实验数据集。

下面具体介绍每种实验数据准备的方法。

1. 利用现有数据集

根据所选择或者所设计的数据库模式来搜索是否有现成的可用数据集，或者根据现有的可用数据集设计相应的数据库模式作为实验数据库模式。

针对每个行业或者领域，在网络上都可以找到大量免费的可用数据集。例如，学术论文数据库 DBLP、国际电影数据库 IMDB、从维基百科（Wikipedia）抽取结构化信息构成的数据集 DBpedia 等。各种数据集都以不同的格式提供，例如，DBLP 以 XML 格式提供、IMDB 以具有一定格式的 Text 文件提供，DBpedia 以 N-Triple 形式提供。有的数据集可以找到相应的代码或者工具，从而把原始格式转换成某种数据库的格式，以便装载到数据库系统中。例如：IMDB 可以用 JMDB（the Java Movie Database）工具导入 PostgreSQL、MySQL 或者 MS SQL Server 数据库；有的数据集需要编写相应的解析程序，以便把原始数据转换成期望的数据库格式；而有的数据集（如 DBpedia）则非常庞大。因此，对于现有的数据集也需要仔细考查，有选择地加以利用。

现有数据集通常是真实的数据集，数据量比较大，是比较理想的实验数据集；但是现有数据集通常没有提供可直接导入数据库的备份数据格式，数据转换和装载入库的工作量会比较大。

2. 通过抓取网络数据构造实验数据集

通过抓取网络数据构造实验数据集是目前流行的一种实验数据采集方式。利用现有的抓取工具，如 Python Scrapy 网络爬虫框架、开源的网络爬虫工具 Web-Harvest 和开源的内容分析工

具 Apache Tika, 或者针对具体网站编写相应的数据抓取程序, 可以采集到大量的网络数据, 进而构造真实的实验数据集。

抓取网络数据需要花费大量的时间和精力, 需要编写程序以解析抓取到的数据, 然后转换成相应的数据库格式, 工作量很大。

3. 利用模拟数据生成工具生成模拟的实验数据集

模拟数据生成工具主要分为三类:

① 数据库辅助设计工具, 如 PowerDesigner, 通过这类工具可以产生测试数据。

② 面向特定数据库模式的专用测试数据产生工具, 如针对 TPC-H 数据库模式的 DBGEN, 通过这类工具可以产生任意规模的模拟数据并导入数据库。

③ 通用测试数据产生工具, 如开源的测试数据生成工具 DBMonster、DataGenerator 和 TestDataBuilder。这类工具都可以在网上搜索到相应的使用说明及下载网址, 使用方便快捷。

模拟数据生成工具可以生成任意规模的实验数据, 适合作为性能测试数据集。但是模拟数据的可读性差, 不利于初学者理解数据含义以及数据之间的联系。

4. 本实验指导所用实验数据集生成方法

本实验指导采用零件供应销售数据库模式作为所有实验示例的数据库模式, 该模式参考了事务处理性能委员会 (Transaction Processing Performance Council, TPC) 为决策支持基准测试而制定的 TPC-H 标准数据库模式。零件供应销售数据库模式包含零件 (Part)、供应商 (Supplier)、顾客 (Customer)、国家 (Nation)、地区 (Region)、零件供应联系 (PartSupp)、订单 (Orders) 和订单明细 (Lineitem) 8 个关系。实验数据集通过抓取网络数据和模拟生成部分数据的综合方法生成, 该数据集的数据规模较大且可读性较强。

本实验指导使用的零件供应销售数据集中, 各表记录数的统计情况参见表 2 (整理好的实验数据集可从本书配套的新形态教材网下载)。

表 2 本实验指导使用的零件供应销售数据集各表的记录统计情况

序号	表名	记录数 (条)	备注
1	Region	6	导入数据
2	Nation	150	导入数据
3	Part	65 755	导入数据
4	Supplier	30 810	导入数据
5	Customer	661 396	导入数据
6	PartSupp	30 000	随机生成数据, 可以生成更多记录
7	Orders	21 100	随机生成数据, 可以生成更多记录, 生成 1 000 条记录花费约 46 s
8	Lineitem	22 026	随机生成数据, 可以生成更多记录, 生成 1 000 条记录花费约 4 s

实验数据收集、整理和生成的过程，实际上也是数据库原理知识的实际应用过程。该过程非常有趣，能够调动学生学习数据库的兴趣，培养学生分析和解决数据库应用问题的能力。因为在生成实验数据的过程中会遇到许多意想不到的问题，例如，在生成数据的过程中如何去除大量数据中的重复记录？如何按照一定的原则补充和完善数据记录中的空值？等等。每一个问题的解决都会让学生学习到解决实际问题的方法和技术。

我们鼓励老师和同学在具有一定的数据库知识后，自己动手准备实验数据集。

四、

数据库课程实验

表 3 列出了本书数据库课程实验的总体情况：共设置了 9 个实验和 26 个实验项目，其中必修实验项目和选修实验项目各 13 个。该表还列出了各实验项目对应的《概论》章节内容，以方便读者复习实验内容。实际教学中各类实验项目可以自由裁剪组合选用。

表 3 本书数据库课程实验一览表

序号	实验名称	开设类别	难易程度	实验项目数 (必修/选修)	实验学时 (必修/选修)	对应《概论》 章节
1	实验准备	必修	适中	1/0	2/0	第 1 章
2	SQL 查询与操纵	必修	适中	5/1	10/2	第 3 章
3	安全性控制	必修	适中	1/1	2/2	第 4 章
4	完整性控制	必修	适中	3/1	6/2	第 5 章
5	数据库设计	必修	适中	1/0	4/0	第 7 章
6	数据库编程与大作业	必修	较难	2/3	10/8	第 8 章
7	数据库性能监视与调优	选修	较难	0/3	0/12	第 10 章
8	数据库备份与恢复	选修	适中	0/3	0/6	第 11 章
9	并发控制	选修	适中	0/1	0/2	第 12 章
合计				13/13	34/34	

说明：实验学时仅列出了课堂学时，部分实验（如实验 6）还需要学生利用较多的课外时间来完成。

第 1 章实验 实验准备

实验准备主要包括关系数据库管理系统（RDBMS）选择、实验环境配置和实验数据准备等工作。

推荐使用国产的数据库管理系统 KingbaseES V9，也可以使用任何一种 RDBMS 产品或开源数据库管理系统。