

数据库技术产生于20世纪60年代,是数据管理的核心技术。数据库管理系统(database management system, DBMS)是大型复杂的基础软件,也是现代信息系统的核心和基础。

数据库技术在发展过程中不断被证明是从应用需求出发开展理论研究与技术创新,再扎扎实实进行产品开发与广泛应用,从而形成良性循环的典范。数据库技术不仅发展成为一门学科,诞生了5位图灵奖得主(参见二维码内容),而且催生并推动了一个巨大的数据库软件产业。



扩展阅读:5位
图灵奖得主介绍

数据库技术是计算机科学与技术的重要分支,是计算机科学与技术中发展最快的领域之一,也是应用最广的技术之一,它极大地促进了计算机应用向各行各业的渗透。随着互联网的发展,广大用户可以通过互联网应用来访问数据库中的数据,例如通过京东、淘宝订购图书、食品和日用品,通过携程订购机票、火车票和酒店,通过网上银行或手机银行转账、检索和管理自己的账户等。小至个人使用的手机APP、车载导航系统,大到各个学校、银行、医院、商店的信息系统,再大到跨国企业和公司的大型信息管理系统,几乎所有的应用系统都是建立在数据库之上,依靠数据库系统存储、管理、处理和分析各类数据。数据库已成为每个人生活中不可或缺的部分。今天大数据应用、云计算技术的迅猛发展,更加凸显出数据库技术的重要性。因此,无论是信息系统的开发者,还是信息系统的运维管理者,或者是信息系统的最终使用者,都须具备一定的数据库基础知识。

本章导读

本章采用“盲人摸象”的方式勾画出数据库系统的轮廓,初步介绍数据库的若干基本概念与发展历史、数据建模与数据模型、数据库系统的模式结构和数据库系统组成等基本知识。目的是让读者了解本课程学什么,以及学习数据库系统的必要性和重要性。

本章首先介绍数据库4个最基本的概念,即数据、数据库、数据库管理系统和数据库系统;讲解数据管理技术的产生和发展过程,从中可以了解数据库系统和文件系统的区别以及数据库系统的优点。接着讲解数据建模的概念、概念模型、数据模型的基本要素,以及层次模型、网状模型、关系模型的基本知识,讨论数据库系统的三级模式结构和两级映像。最后介绍

数据库系统的组成以及数据库系统的体系结构。

学习本章应把注意力放在掌握基本概念和基本知识方面,为进一步学习后面的章节打好基础。**本章的难点是读者要在短时间内接触数据库领域诸多基本概念**,有些概念对于刚步入数据库领域的读者来说会感到比较抽象,不易理解。但不要紧,随着学习的循序渐进,后续章节将继续深入讲解这些概念,使读者逐步掌握和理解。

1.1 数据库系统概述

在系统地介绍数据库的基本概念之前,这里首先介绍一些数据库最常用的术语和基本概念。

1.1.1 数据库的4个基本概念

数据、数据库、数据库管理系统和数据库系统,是与数据库技术密切相关的4个基本概念。

1. 数据

数据(data)是数据库中存储的基本对象。对于数据,大多数人的第一个反应就是数字,例如93、1 000、99.5、-330.86、¥6 880、\$726等。其实数字只是最常见的一种数据,是对数据的一种传统和狭义的理解。广义的理解认为数据的种类很多,例如文本(text)、图形(graph)、图像(image)、音频(audio)、视频(video)、互联网上的博客、微信中的聊天记录、学生的档案记录、个人的网购记录、医院的患者病历等,都是数据。

为了认识世界,交流信息,人们需要描述事物。可以对数据做如下定义:描述事物的符号记录称为数据。描述事物的符号可以是数字,也可以是文字、图形、图像、音频、视频等。数据有多种表现形式,它们都可以经过数字化后存入计算机。

在现代计算机系统中数据的概念是广义的。早期的计算机系统主要用于科学计算,处理的数据是数值型数据,如整数、实数、浮点数等。现在的计算机存储和处理的对象十分广泛,用于表示这些对象的数据也随之变得越来越复杂。

数据的表现形式还不能完全表达其内容,需要经过解释,数据和关于数据的解释是不可分的。例如,93是一个数据,它可以是一个学生某门课程的考试成绩,也可以是某个人的体重,还可以是计算机科学与技术专业2018级的学生人数。数据的解释是指对数据含义的说明,数据的含义称为数据的语义,数据与其语义是不可分的。

在日常生活中,人们可以直接用自然语言(如汉语)描述事物。例如,可以这样描述某校一个计算机科学与技术专业学生的基本情况:学号为20180002、姓名为刘晨的女生,1999年9月1日出生,计算机科学与技术专业。在计算机中则常用如下的形式描述:

(20180002, 刘晨, 女, 1999-9-1, 计算机科学与技术)

即把学生的学号、姓名、性别、出生日期、主修专业等组织在一起,构成一条记录。这里的学

生记录就是描述学生的数据,这样的数据是有结构的。记录是计算机中表示和存储数据的一种格式或一种方法。

2. 数据库

数据库(database, DB),顾名思义,是存放数据的仓库。只不过这个仓库是在计算机存储设备上,而且数据是按一定的格式存放的。

人们采集一个应用所需要的大量数据之后,应将其保存起来以供进一步加工处理,并从中抽取有用信息。在数据采集手段越来越方便的今天,数据量急剧增加,过去人们把数据存放在文件柜里,现在存储在数据库中是最佳选择。借助数据库技术保存和管理大量复杂的数据,可以充分地利用这些宝贵的信息资源。

所谓数据库,就是长期存储在计算机内有组织、可共享的大量数据的集合。数据库中的数据按一定的数据模型组织、描述和存储,具有较小的数据冗余(data redundancy)、较高的数据独立性(data independency)和可扩展性(scalability),并可为各种用户共享。数据库的这些特性将在 1.1.2 小节继续讲解。

3. 数据库管理系统

了解数据和数据库的初步概念之后,下一个问题就是如何科学地组织和存储这些数据,以及如何高效地处理和维护数据。完成该任务的即为数据库管理系统。

数据库管理系统是位于用户与操作系统之间的数据管理软件。它和操作系统一样是计算机的基础软件,也是一类大型复杂的软件系统。它的主要功能包括以下几个方面。

① 数据定义功能。数据库管理系统提供数据定义语言(data definition language, DDL),用户通过它可以方便地对存储在数据库中的数据对象的组成与结构进行定义。

② 数据组织、存储和管理功能。数据库管理系统要分类组织、存储和管理各种数据,包括数据字典、用户数据、数据存取路径等。要确定以何种文件结构和存取方式在存储器上组织这些数据,以及如何实现数据之间的联系。数据组织和存储的基本目标是提高存储空间利用率和方便存取,可提供多种存取方法(如索引查找、哈希查找、顺序查找等)来提高存取效率。

③ 数据操纵功能。数据库管理系统还提供数据操纵语言(data manipulation language, DML),用户可以使用它操纵数据,实现对数据库的基本操作,如查询、插入、删除和修改等。

④ 数据库的事务管理和运行管理功能。数据库在建立、运行和维护时由数据库管理系统统一管理和控制,以保证事务的正确运行、数据的安全性、完整性、多用户对数据的并发使用,以及发生故障后的系统恢复。

⑤ 数据库的建立和维护功能。数据库的建立和维护功能包括数据库初始数据的输入和转换功能,数据库的转储和恢复功能,数据库的重组、性能监视和数据分析等功能。这些功能通常是由一些实用程序或管理工具完成的。

⑥ 其他功能。其他功能包括数据库管理系统与网络中其他软件系统的通信功能、一个数

数据库管理系统与另一个数据库管理系统或文件系统的数据转换功能、异构数据库之间的互访和互操作功能等。

4. 数据库系统

数据库系统(database system, DBS)是指引入数据库后的计算机系统,一般是指由数据库、数据库管理系统(及其应用开发工具)、应用系统和数据库管理员(database administrator, DBA)组成的存储、管理、处理和维护数据的系统。应当指出的是,数据库的建立、使用和维护等工作只靠一个数据库管理系统远远不够,还要有专门的人员来完成,这些人被称为数据库管理员。

数据库系统可以用图 1.1 表示。其中数据库提供数据的存储功能,数据库管理系统提供数据的组织、存取、管理和维护等基础功能,应用系统根据应用需求使用数据库,数据库管理员负责数据库管理系统的运行。图 1.2 是引入数据库管理系统后计算机系统的层次结构。




图 1.1 数据库系统



图 1.2 引入数据库管理系统后计算机系统的层次结构

在不引起混淆的情况下,人们常常把数据库系统简称为数据库。

1.1.2 数据管理技术的产生和发展

数据库技术是为满足数据管理任务的需要而产生的。数据管理是指对数据进行分类、组织、编码、存储、检索和维护,它是数据处理的中心问题。而数据处理是指对各种数据进行收集、存储、加工和传播的一系列活动的总和。

在应用需求的推动下,在计算机软硬件发展的基础上,数据管理技术经历了人工管理、文件系统、数据库系统三个阶段。这三个阶段的比较如表 1.1 所示。

表 1.1 数据管理技术三个阶段的比较

对比项	人工管理阶段	文件系统阶段	数据库系统阶段
应用领域	科学计算	科学计算、数据管理	大规模数据管理
主要硬件	无直接存取存储设备	磁盘、磁鼓	大容量磁盘、磁盘阵列
主要软件	没有操作系统, 没有管理数据的专门软件	有文件系统	有数据库管理系统
数据处理方式	批处理	联机实时处理、批处理	联机实时处理、分布处理、批处理
数据管理者	人(程序员)	文件系统	数据库管理系统
数据面向对象	某一应用程序	某一应用	现实世界(部门、企业、跨国组织等)
数据共享程度	不共享, 冗余度极高	共享性弱, 冗余度高	共享性强, 冗余度低且易扩充
数据独立性	不独立, 完全依赖应用程序	独立性弱	具有较强的物理独立性和一定的逻辑独立性
数据结构化	无结构	记录内有结构、整体无结构	整体结构化, 用数据模型描述
数据控制能力	应用程序自己控制	应用程序自己控制	由数据库管理系统提供数据安全性、完整性、并发控制和数据库恢复功能

1. 人工管理阶段

20 世纪 50 年代中期以前, 计算机主要用于科学计算。当时的硬件状况是外存只有纸带、卡片、磁带, 没有磁盘等直接存取存储设备; 软件状况是没有操作系统, 没有管理数据的专门软件; 数据处理方式是批处理。

人工管理数据具有如下特点:

① 数据不保存。当时的计算机主要用于科学计算, 一般不需要长期保存数据, 只是在计算时将数据输入, 用完就撤走。不仅对用户数据如此处置, 对系统软件有时也是这样处置。

② 应用程序管理数据。数据需要由程序员在应用程序中设计、说明(定义)和管理, 没有相应的软件系统负责数据的管理工作。应用程序不仅要规定数据的逻辑结构, 而且要规定数据的物理结构, 包括存储结构、存取方法、输入方式等。因此程序员的负担很重。

③ 数据不共享。数据是面向应用程序的, 一组数据只能对应一个程序。当多个应用程序涉及某些相同的数据时必须各自定义, 无法互相利用、互相参照, 因此程序与程序之间有大量的冗余数据。

④ 数据不具有独立性。数据独立性是指数据与应用程序相互独立, 即数据的结构发生变化后, 应用程序不必做相应的修改。

在人工管理阶段, 数据由程序员在应用程序中定义, 数据结构一旦发生变化, 就需要修改应用程序, 数据完全依赖于应用程序, 称之为数据缺乏独立性, 这就加重了程序员的负担。

在人工管理阶段, 应用程序与数据(表现为数据集)之间的一一对应关系可用图 1.3 表示。

2. 文件系统阶段

20 世纪 50 年代后期~20 世纪 60 年代中期, 这时硬件方面已有磁盘、磁鼓等直接存取存储设备; 软件方面表现为操作系统中已有专门的数据管理软件, 一般称为文件系统; 处理方式不仅能够进行批处理, 而且能够进行联机实时处理。

用文件系统管理数据具有如下特点:

① 数据可以长期保存。由于计算机主要用于数据处理, 一般将数据长期保留在外存上以反复进行查询、修改、插入和删除等操作。

② 数据由专门的软件进行管理, 文件系统把数据组织成相互独立的数据文件, 利用“按文件名访问, 按记录进行存取”的管理技术, 提供了对文件进行打开与关闭、对记录进行读取和写入等存取方式。

文件系统实现了记录内的结构性。但是, 文件系统仍存在以下缺点:

① 数据共享性弱, 冗余度高。在文件系统中, 一个(或一组)文件基本上对应于一个应用程序, 即文件仍然是面向应用的。当不同的应用程序具有部分相同的数据时也必须建立各自的文件, 而不能共享相同的数据, 因此数据的冗余度高, 浪费存储空间。同时, 相同数据的重复存储与各自管理容易造成数据的不一致性, 给数据的修改和维护带来困难。

② 数据独立性弱。文件系统文件是为某一特定应用服务的, 文件的逻辑结构针对具体的应用设计和优化, 因此要想对文件中的数据再增加一些新的应用会很困难。而且, 当数据的逻辑结构改变时, 应用程序中文件结构的定义必须修改, 应用程序中对数据的使用也要改变, 因此数据依赖于应用程序, 缺乏独立性。可见, 文件系统仍然是一个不具有弹性的无整体结构的数据集合, 即文件之间是孤立的, 不能反映现实世界事物之间的内在联系。

在文件系统阶段, 应用程序与数据(表现为文件组)之间的关系如图 1.4 所示。



图 1.3 人工管理阶段应用程序与数据之间的——对应关系




图 1.4 文件系统阶段应用程序与数据之间的对应关系

3. 数据库系统阶段

20 世纪 60 年代后期以来, 计算机管理的对象规模越来越大, 应用范围越来越广泛, 数据量急剧增长。同时, 多种应用、多种语言互相交错地共享数据集的要求越来越强烈。

这时硬件方面已有大容量磁盘和磁盘阵列,硬件价格下降;软件方面则表现为软件价格上升,编制和维护系统软件及应用程序所需的成本相对增加;在处理方式上更多地应用联机实时处理,并开始提出和考虑分布式处理。在这种背景下,以文件系统作为数据管理手段已不能满足应用的需求,于是为解决多用户、多应用共享数据的需求,使数据为尽可能多的应用服务,数据库技术便应运而生,出现了统一管理数据的专门软件系统——数据库管理系统。

数据库系统阶段的数据具有如下特点。

(1) 整体数据的结构化

数据库系统阶段实现了整体数据的结构化,这是数据库的主要特征之一,也是数据库系统阶段与文件系统阶段的本质区别。

在文件系统中,文件中的记录具有结构,但是记录的结构和记录之间的联系被固化在程序中,需要由程序员加以维护。这种工作模式既加重了程序员的负担,又不利于结构的变动。二维码所示内容通过一个例子来比较文件系统操作与数据库系统操作的差异,从中可看到数据库系统的优点。



扩展阅读:文件
系统与数据库系
统操作比较示例

所谓整体数据的结构化,是指数据库中的数据不再是仅仅针对某一个应用,而是面向整个组织或企业的多种应用需求;不仅数据本身是结构化的,而且整体数据也是结构化的,即数据之间具有联系。也就是说,不仅要考虑某个应用的数据结构,还要考虑整个组织的数据结构。

例如,一个学校的信息系统不仅要考虑教务处的课程管理、学生选课管理、成绩管理,还要考虑学生处的学生学籍管理、研究生院的研究生管理、人事处的教师人事管理、科研处的科研管理等。因此,学校信息系统中的学生数据就要面向各个部门的应用,而不仅仅是面向教务处的一个学生选课应用。图 1.5 为“高校本科教务管理”信息系统^①中与学生有关的数据结构。




图 1.5 “高校本科教务管理”信息系统中与学生有关的数据结构

^① 本书用一个实例——“高校本科教务管理”信息系统将数据库系统知识点讲解和设计样例贯穿起来,随着知识点讲解的深入,该实例的内容也将根据实际情况不断丰富和变化。相关介绍详见附录。

图 1.5 所示的数据组织方式为各部门的应用提供了必要的记录,使整体数据结构化了。这就要求在描述数据时不仅要描述数据本身,还要描述数据之间的联系。

记录的结构和记录之间的联系由数据库管理系统维护,从而减轻了程序员的负担,提高了工作效率。

在数据库系统中,不仅整体数据是结构化的,而且存取数据的方式也很灵活,可以存取数据库中的某一个或一组数据项、一条记录或一组记录;而在文件系统中,数据的存取单位是记录,粒度不能细到数据项。

(2) 数据的共享性强、冗余度低且易于扩充

数据库系统从整体角度看待和描述数据,数据不再是面向某个应用,而是面向整个系统。因此,数据可以被多个用户或多个应用通过不同的接口、不同的编程语言共享使用。这种较强的数据共享性可以大大降低数据的冗余度,节省存储空间,还能避免数据的不相容性与不一致性。

所谓数据的不一致性,是指同一数据不同副本的值不一样。采用人工管理或文件系统管理时,由于数据被重复存储,不同的应用使用和修改不同的副本就很容易造成数据的不一致;而在数据库中数据共享则减少了由数据冗余造成的不一致现象。

数据库数据的共享性强还使其易于增加新的应用,易于扩充,这也是数据库系统“弹性大”的原因。我们可以选取整体数据的各种子集用于不同的应用系统,当应用需求改变或增加时,只要重新选取不同的子集或加上一部分数据即可满足新的需求。

(3) 数据的独立性强

数据的独立性强是数据库数据的一个显著优点。数据独立性已成为数据库领域的一个常用术语和重要概念,其目标是应用程序与数据(定义)相分离。数据的独立性包括数据的物理独立性和数据的逻辑独立性。

数据的物理独立性,是指用户的应用程序与数据库中数据的物理存储是相互独立的。也就是说,数据在数据库中怎样存储是由数据库管理系统管理的,用户程序不需要了解,这样当数据的物理存储改变时应用程序不用改变。

数据的逻辑独立性,是指用户的应用程序与数据库的逻辑结构是相互独立的。也就是说,数据的逻辑结构改变时用户程序也可以不变。

数据的独立性是由数据库管理系统提供的两级映像功能来保证的,相关内容将在 1.3.3 小节进行讨论。

数据的独立性把数据的定义从应用程序中分离出去,而存取数据的方法又由数据库管理系统负责提供,从而简化了应用程序的编制,大大减少了应用程序的维护和修改工作。

(4) 数据由数据库管理系统统一管理和控制

数据库数据的共享将会带来数据库的安全隐患,且因这种共享是并发性(concurrency)的,即多个用户可以同时存取数据库中的数据,甚至可以同时存取数据库中的同一个数据,这又会带来不同用户间相互干扰的隐患。另外,数据库中数据的正确性与一致性也必须得到保障。为

此,数据库管理系统还必须提供以下几方面的数据管理功能。

① 数据的安全性(security)保护。数据的安全性是指保护数据以防不合法使用造成数据泄露和破坏。每个用户只能依照规定对某些数据按指定方式进行使用和处理,相关内容将在第4章进行讲解。

② 数据的完整性(integrity)检查。数据的完整性是指数据的正确性、有效性和相容性。完整性检查将数据控制在有效的范围内,并保证数据之间满足一定的关系,相关内容将在第5章进行讲解。

③ 数据的并发控制。当多个用户的并发进程同时存取、修改数据库时,可能会因相互干扰而得到错误的结果或使数据库的完整性遭到破坏。因此,必须对多用户的并发操作加以控制和协调,以保证一个用户事务的执行不受其他事务的干扰,从而避免造成数据的不一致性。相关内容将在第12章进行讲解。

④ 数据库的恢复(recovery)。计算机系统的硬件/软件故障、操作失误以及蓄意破坏等会影响数据库中数据的正确性,甚至造成数据库部分或全部数据的丢失。数据库管理系统必须具有将数据库从错误状态恢复到某一已知的正确状态(亦称为完整状态或一致状态)的功能,即数据库的恢复功能。相关内容将在第11章进行讲解。

在数据库系统阶段,应用程序与数据(表现为数据库)之间的对应关系可用图1.6表示。



图 1.6 数据库系统阶段应用程序与数据之间的对应关系

综上所述,数据库是长期存储在计算机内的有组织、可共享的大量数据的集合。它可以供各种用户共享,具有最小的冗余度和较强的数据独立性。数据库管理系统在数据库建立、运维时对数据库进行统一控制,以保证数据的完整性和安全性,并在多用户同时使用数据库时进行并发控制,在发生故障后对数据库进行恢复。

数据库系统的出现,使信息系统从以加工数据的程序为中心转向以共享的数据库为中心的新阶段,即以软件为中心向以数据为中心的计算机平台的迁移。这样既便于数据的集中管理,又能简化应用系统的研制和维护,提高了数据的利用率和决策的可靠性。

数据库技术的发展经历了20世纪60年代的网状数据库、层次数据库,20世纪70年代的关系数据库,以及20世纪80年代的以面向对象模型为主要特征的数据库系统。随着大数据应

用的迅猛发展,又陆续出现了众多新型的数据模型和数据库管理系统。

数据库技术与网络通信技术、面向对象程序设计技术、并行/分布式计算技术、云计算技术、人工智能技术、新硬件技术等互相渗透、互相结合,成为当前数据库技术发展的主要特征。我们将在新技术篇的第14章中介绍数据库技术的最新发展。

1.2 数据模型

数据库技术是计算机领域中发展最快的技术之一,其发展是沿着数据模型的主线推进的。模型,特别是具体模型对人们来说并不陌生。一张地图、一组建筑设计沙盘、一架精致的航模飞机都是具体的模型,一眼望去就会使人联想到真实生活中的事物。模型是对现实世界中某个对象特征的模拟和抽象。例如,航模飞机是对生活中飞机的一种模拟和抽象,它可以模拟飞机的起飞、飞行和降落,并抽象了飞机的基本特征——机头、机身、机翼、机尾等。

数据模型(data model)也是一种模型,它是对现实世界数据特征的抽象。也就是说,数据模型是用来描述数据、组织数据和对数据进行操作的。

由于计算机不可能直接处理现实世界中的具体事物,所以人们必须事先把具体事物转换成计算机能够处理的数据,也就是首先要数字化,把现实世界中具体的人、物、活动等用数据模型这个工具来抽象、表示和处理。通俗地讲,数据模型就是现实世界的模拟。

现有的数据库系统均是基于某种数据模型的,数据模型是数据库系统的核心和基础。因此,了解数据模型的基本概念是学习数据库的基础。

1.2.1 数据建模

把现实世界中的具体事物抽象、组织为某一数据库管理系统支持的数据模型,这个过程称为**数据建模(data modeling)**。

在数据库系统中,数据建模过程通常分为两步进行。

1. 建立概念模型

首先将现实世界抽象为信息世界。也就是把现实世界中的客观对象抽象为某一种信息结构,这种信息结构并不依赖于具体的计算机系统,不是某一个数据库管理系统支持的数据模型,而是概念级的模型,因此称为**概念模型(conceptual model)**。

概念模型是按用户的观点来对数据建模,主要用于数据库设计。从现实世界到概念模型的建模任务由数据库设计人员完成,也可以通过数据库设计工具辅助设计人员完成。

2. 将概念模型转换为数据模型

接下来将信息世界转换为机器世界,即把概念模型转换为计算机上某一数据库管理系统支持的数据模型。

数据模型是按计算机系统的观点对数据建模,是数据库管理系统支持的,用于数据库管理系统的实现。从概念模型到数据模型的转换由数据库设计人员完成,也可以通过数据库设计工

具辅助设计人员完成。

上述抽象过程如图 1.7 所示。



图 1.7 现实世界中客观对象的抽象过程

下面首先介绍概念模型，然后讲解数据模型的基本要素，并介绍几种不同的数据模型。

1.2.2 概念模型

由图 1.7 可以看出，概念模型实际上是现实世界到机器世界的一个中间层次。

概念模型用于信息世界的建模，是现实世界到信息世界的第一层抽象，是数据库设计人员进行数据库设计的有力工具，也是数据库设计人员和用户之间进行交流的语言。因此，概念模型一方面应具有较强的语义表达能力，能够方便、直接地表达应用中的各种语义知识，另一方面还应简单、清晰、易于用户理解。

1. 信息世界中的基本概念

信息世界主要涉及以下一些概念。

① 实体(entity)。客观存在并可相互区别的事物称为实体。实体可以是具体的人、事、物，也可以是抽象的概念或联系。例如，一个职工、一个学生、一个部门、一门课等都是实体。

② 属性(attribute)。实体所具有的某一特性称为属性。一个实体可以由若干个属性来刻画。例如，“学生”实体可以由“学号”“姓名”“性别”“出生日期”“主修专业”等属性组成，属性组合(20180003, 王敏, 女, 2001-8-1, 计算机科学与技术)即表征了一个学生。

③ 码(key)。唯一标识实体的属性集称为码。例如，“学号”是“学生”实体的码。

④ 实体类型(entity type)。具有相同属性的实体必然具有共同的特征和性质。用实体名及其属性名集合来抽象和刻画同类实体，称为实体类型，或称实体型。例如，学生(学号, 姓名, 性别, 出生日期, 主修专业)就是一个实体型。

⑤ 实体集(entity set)。同一类型实体的集合称为实体集。例如，全体学生就是一个实

体集。

⑥ 联系 (relationship)。在现实世界中,事物内部以及事物之间是有联系的,这些联系在信息世界中反映为实体(型)内部的联系和实体(型)之间的联系。实体内部的联系通常是指组成实体的各属性之间的联系,实体之间的联系通常是指不同实体集之间的联系。

实体之间的联系有一对一、一对多和多对多等多种类型(具体内容将在第7章7.3.2小节E-R模型中进行介绍)。

2. 概念模型的一种表示方法: 实体-联系模型

概念模型是对信息世界建模,所以概念模型应该能够方便、准确地表示上述信息世界中的常用概念。概念模型的表示方法很多,其中最为常用的是P. P. S. Chen于1976年提出的**实体-联系模型**(entity-relationship model),简称**E-R模型**。该方法用E-R图(E-R diagram)来描述现实世界的概念模型。图1.8是学生选课E-R图示例。




图 1.8 学生选课 E-R 图示例

图1.8抽象了学校中的“学生”和“课程”两个客观事物:“学生”实体和“课程”实体;还抽象了现实世界中事物之间的联系:一门课程可以有多个学生选修,一个学生可以选修多门课程,用“课程”实体与“学生”实体的多对多($m:n$)联系来描述。

有关如何认识和分析现实世界,从中抽取实体、实体的属性和实体之间的联系,建立概念模型,画出E-R图等方法,将在第7章数据库设计中详细讲解。

1.2.3 数据模型的三要素

一般地讲,数据模型是严格定义的一组概念的集合。这些概念精确地描述了系统的静态特性、动态特性和完整性约束(integrity constraint)。因此数据模型通常由数据结构、数据操纵和完整性约束三部分组成,称为数据模型的三要素。

1. 数据结构

数据结构描述数据库的组成对象以及对象之间的联系。也就是说,数据结构描述的内容有两类:一类是与对象的类型、内容、性质有关的,如网状模型中的数据项、记录,关系模型中的域、属性、关系等;一类是与数据之间的联系有关的对象,如网状模型中用系(set)表示记录之间的联系。

数据结构是刻画一个数据模型性质的最重要的方面。因此,在数据库系统中人们通常按照其数据结构的类型来命名数据模型。例如,层次结构、网状结构和关系结构的数据模型分别命名为层次数据模型、网状数据模型和关系数据模型,简称为层次模型、网状模型和关系模型。

总之,数据结构是所描述的对象类型的集合,是对系统静态特性的描述。

2. 数据操纵

数据操纵是指对数据库中各种对象(型)的实例(值)允许执行的操作的集合,包括操作及有关的操作规则。

数据库主要有查询和更新(包括插入、删除、修改)两大类操作。数据模型必须定义这些操作的确切含义、操作符号、操作规则(如优先级)以及实现操作的语言。

数据操纵是对系统动态特性的描述。

3. 完整性约束

完整性约束是一组完整性规则。完整性规则是给定的数据模型中的数据及其联系所具有的制约和依存规则,用以限定符合数据模型的数据库状态以及状态的变化,以保证数据的正确、有效和相容。

数据模型应该反映和规定其必须遵守的基本和通用的完整性约束。例如,在关系模型中,任何关系必须满足实体完整性和参照完整性。本书第2章关系模型、第5章数据库完整性将详细讨论这两类完整性约束。

注意,这里讲的数据模型都是逻辑上的,它们都能用某种语言描述,使数据库管理系统能够理解。被数据库管理系统支持的数据视图,也是用户可以用这种语言描述和处理的数据结构。

这些数据模型将以一定的组织方式存储在数据库管理系统中,是数据模型在数据库管理系统内部的物理存储结构,人们称之为数据的物理模型。

物理模型描述数据在数据库管理系统内部的数据组织和存取方法的实现,包括存储结构和索引结构的物理实现。例如,记录的表示、记录如何在一个物理块中组织存储、有哪些索引结构、索引的组织方式和查找方法等。常用的索引有顺序表索引、B+树索引和哈希索引等,本书第9章关系数据库存储管理将详细讲解。

数据结构、数据操纵和完整性约束这三方面内容完整地描述了一个数据模型,其中数据结构是刻画模型性质的最基本的内容。为了使读者对数据模型有一个初步认识,下面简要介绍层次模型(hierarchical model)、网状模型(network model)和关系模型(relational model)。

1.2.4 层次模型

在层次模型中实体用记录表示,实体的属性对应记录的字段(或数据项)。这样可以将实体之间的联系转换成记录之间的两两联系。

在层次模型中,数据结构的单位是基本层次联系。所谓基本层次联系是指两个记录及其之

间的一对多(包括一对一)联系,如图 1.9 所示。

图中 R_i 位于联系 L_{ij} 的始点,称为双亲(parent)结点, R_j 位于联系 L_{ij} 的终点,称为子女(child)结点。

层次模型是数据库系统中最早出现的数据模型,层次数据库系统采用层次模型作为数据的组织方式。层次数据库系统的典型代表是 IBM 公司的 IMS(information management system),这是 1968 年 IBM 公司推出的第一个大型商用数据库管理系统,曾经得到广泛的使用。

层次模型用树形结构表示各类实体以及实体间的联系。现实世界中许多实体之间的联系本来就呈现出一种很自然的层次关系,如行政机构、家族关系等。

1. 层次模型的数据结构

在数据库中,满足下面两个条件的基本层次联系的集合为层次模型:

- ① 有且只有一个结点没有双亲结点,这个结点称为根结点。
- ② 根以外的其他结点有且只有一个双亲结点。

在层次模型中,每个结点表示一个记录类型,记录类型之间的联系用结点之间的连线(有向边)表示,这种联系是双亲结点与子女结点之间的一对多联系。这就使得层次数据库系统只能处理一对多的实体联系。

每个记录类型可包含若干字段,这里记录类型描述的是实体型,字段描述实体的属性。各个记录类型及其字段都必须命名。各个记录类型、同一记录类型中的各个字段不能同名。每个记录类型可以定义一个排序字段,也称为码字段,如果定义该排序字段的值是唯一的,则它能唯一地标识一个记录值。

一个层次模型在理论上可以包含任意有限个记录类型和字段,但任何实际的系统都会因为存储容量或实现复杂度而限制模型中包含的记录类型和字段的数量。

在层次模型中,同一双亲结点的子女结点称为兄弟(twin 或 sibling)结点,没有子女结点的结点称为叶(leaf)结点。图 1.10 给出了一个层次模型示例,其中, R_1 为根结点; R_2 和 R_3 为兄弟结点,且是 R_1 的子女结点; R_4 和 R_5 为兄弟结点,且是 R_2 的子女结点; R_3 、 R_4 和 R_5 为叶结点。




图 1.9 基本层次联系




图 1.10 一个层次模型示例

从图 1.10 中可以看到层次模型像一棵倒立的树,每个结点的双亲结点都是唯一的。

层次模型的一个基本的特点是,任何一个给定的记录值只能按其层次路径查看,没有一个

子女记录值能够脱离双亲记录值而独立存在。

图 1.11 是“高校本科教务管理”信息系统中“学生学籍管理”子系统的层次模型示意图。该层次模型有 4 个记录类型，其中记录类型“学院”是根结点，由三个字段(学院编号、学院名、建院时间)组成，它有两个子女结点“系”和“学生”。记录类型“系”是“学院”的子女结点，同时又是“教师”的双亲结点，它由 4 个字段(系编号、系名、联系人、联系方式)组成。记录类型“学生”由 5 个字段(学号、姓名、性别、出生日期、主修专业)组成。记录类型“教师”由 4 个字段(职工号、姓名、职称、出生日期)组成。“学生”与“教师”是叶结点，它们没有子女结点。由“学院”到“系”、由“系”到“教师”、由“学院”到“学生”均是一对多的联系。




图 1.11 “学生学籍管理”子系统的层次模型示意图

图 1.12 是图 1.11 所示层次模型对应的一个值。该值是由“信息学院”一个记录值及其所有后代记录值组成的一棵树。其中，“信息学院”有三个系记录值和三个学生记录值，“计算机系”有 4 个教师记录值，“数学系”有两个教师记录值。




图 1.12 “学生学籍管理”子系统层次模型的一个值

2. 层次模型的数据操纵与完整性约束

层次模型的数据操纵主要有查询、插入、删除和更新操作。在进行插入、删除和更新操作

时要满足层次模型的完整性约束。

进行插入操作时,如果没有相应的双亲结点值就不能插入其子女结点值。例如在图 1.12 所示的层次数据库中,若新调入一名教师,但尚未分配到某个系,这时就不能将新教师插入数据库。

进行删除操作时,如果删除双亲结点值,则相应的子女结点值也将被同时删除。例如在图 1.12 所示的层次数据库中,若删除“数学系”,则“数学系”所有教师的数据将全部丢失。

3. 层次模型的优缺点

层次模型的优点主要有:

① 层次模型的数据结构比较简单清晰。

② 层次数据库的查询效率高。层次模型中记录之间的联系用有向边表示,这种联系在数据库管理系统中常用指针来实现,因此这种联系也就是记录之间的存取路径。当要存取某个结点的记录值时,数据库管理系统沿着这条路径很快就能找到该记录值,所以层次数据库的性能优良,存取效率高。

③ 层次数据模型提供了良好的完整性约束支持。

层次模型的缺点主要有:

① 现实世界中很多联系是非层次性的,如结点之间具有多对多联系,不适合用层次模型表示。

② 如果一个结点具有多个双亲结点,用层次模型表示这类联系就很笨拙,只能通过引入冗余数据(易产生不一致性)或创建非自然的数据结构(引入虚拟结点)来解决,对插入和删除操作的限制比较多,因此应用程序的编写比较复杂。

③ 查询子女结点必须通过双亲结点。

④ 由于结构严密,层次命令趋于程序化。

可见,用层次模型对具有一对多层次联系的部门描述非常自然、直观,容易理解。这是层次数据库的突出优点。

1.2.5 网状模型

在现实世界中事物之间的联系更多为非层次关系,用层次模型表示非树形结构很不直接,而网状模型则可以克服这一弊端。

网状数据库系统采用网状模型作为数据的组织方式,其典型代表是 DBTG 系统,亦称 CODASYL 系统。这是 20 世纪 70 年代数据系统语言会议(conference on data system language, CODASYL)下属的数据库任务组(data base task group, DBTG)提出的一个系统方案。DBTG 系统虽然不是实际的数据库系统软件,但是它的基本概念、方法和技术具有普遍意义,对于网状数据库系统的研制和发展产生了重大的影响。后来不少系统都采用 DBTG 系统或者简化的 DBTG 系统模型,如 Cullinet Software 公司的 IDMS、Univac 公司的 DMS-1100、Honeywell 公司的 IDS/2、HP 公司的 IMAGE 等。

1. 网状模型的数据结构

在数据库中,把满足以下两个条件的基本层次联系集合称为网状模型:

- ① 允许一个以上的结点无双亲结点。
- ② 一个结点可以有多于一个的双亲结点。

网状模型是一种比层次模型更具普遍性的结构。它去掉了层次模型的两个限制,允许多个结点没有双亲结点,且允许结点有多个双亲结点;此外它还允许两个结点之间有多种联系(称之为复合联系)。因此,网状模型可以更直接地描述现实世界,而层次模型实际上是网状模型的一个特例。

与层次模型一样,网状模型中每个结点表示一个记录类型(实体型),每个记录类型可包含若干个字段(实体的属性),结点间的连线表示记录类型(实体型)之间一对多的联系。

从网状模型的定义可以看出,层次模型中子女结点与双亲结点的联系是唯一的,而在网状模型中这种联系可以不唯一。因此要为每个联系命名,并指出与该联系有关的双亲结点和子女结点。例如,图 1.13(a)中 R_3 有两个双亲结点 R_1 和 R_2 ,因此把 R_1 与 R_3 之间的联系命名为 L_1 , R_2 与 R_3 之间的联系命名为 L_2 。图 1.13(a)(b)(c)都是网状模型的例子。




图 1.13 网状模型示例

下面以“学生选课”子系统为例,观察网状数据库是怎样组织数据的。

按照常规语义,一个学生可以选修若干门课程,某一课程可以被多个学生选修,因此学生与课程之间是多对多的联系。因为 DBTG 系统模型不能表示记录之间多对多的联系,为此引进一个“学生选课”的连接记录,它由 5 个字段(学号、课程号、成绩、开课学期,教学班)组成,表示某个学生在某个学期的某个教学班选修了某一门课程及其成绩。这样,“学生选课”子系统共包含 3 个记录类型“学生”“课程”和“学生选课”(如图 1.14 所示)。

每个学生可以选修多门课程,显然对“学生”记录类型中的一个值,“学生选课”记录类型中可以有多个值与之联系,而“学生选课”记录类型中的一个值,只能与“学生”记录类型中的一个值联系。“学生”与“学生选课”之间的联系是一对多的联系,联系名为“S-SC”。同样,“课程”与“学生选课”之间的联系也是一对多的联系,联系名为“C-SC”。

2. 网状模型的数据操纵与完整性约束

一般来说,网状模型没有层次模型那样严格的完整性约束,但具体的网状数据库系统对数



图 1.14 “学生选课”子系统的网状模型

据操纵都加了一些限制, 提供了一定的完整性约束。

例如, DBTG 系统在模式数据定义语言中提供了定义 DBTG 数据库完整性的若干概念和语句, 主要有:

① 支持记录类型中“码”的概念, 码即唯一标识记录类型的数据项的集合。例如, 图 1.14 的“学生”记录类型中“学号”是码, 因此数据库中不允许“学号”出现重复值。

② 保证一个联系中双亲结点和子女结点之间是一对多的联系。

③ 可以支持双亲结点和子女结点之间的某些约束条件。例如, 有些子女结点值要求双亲结点值存在才能插入, 双亲结点值删除时也连同删除。例如图 1.14 中“学生选课”记录类型就应该满足这种约束条件, 学生选课的记录值必须是数据库中存在的某一学生选修存在的某一门课的记录。DBTG 系统提供了“属籍类别”(membership class)的概念来描述这类约束条件。

3. 网状模型的优缺点

网状模型的优点主要有:

① 能够更为直接地描述现实世界, 如一个结点可以有多个双亲结点, 结点之间可以有多种联系。

② 具有良好的性能, 存取效率较高。

网状模型的缺点主要有:

① 结构比较复杂, 而且随着应用环境的扩大数据库的结构变得越来越复杂, 不利于最终用户掌握。

② 数据定义语言和数据操纵语言比较复杂, 并且要嵌入某一种高级语言(如 COBOL、C)中, 用户不容易掌握和使用。

③ 由于记录类型之间的联系是通过存取路径实现的, 应用程序在访问数据时必须选择适当的存取路径, 因此用户必须了解系统结构的细节, 加重了编写应用程序的负担。

1.2.6 关系模型

关系模型是最重要的一种数据模型。关系数据库系统采用关系模型作为数据的组织方式。

1970 年, 美国 IBM 公司 San Jose 研究室的研究员 Edgar F. Codd 首次提出了数据库系统的关系模型, 开创了数据库关系方法和关系数据理论的研究, 为关系数据库技术奠定了理论基础。Edgar F. Codd 也因该项杰出工作于 1981 年获得图灵奖。

20 世纪 80 年代以来, 计算机厂商新推出的数据库管理系统几乎都支持关系模型, 非关系数据库系统的产品也大都加上了关系接口。因此本书的重点将放在关系数据库上, 后面有关章节将详细介绍关系数据库。

1. 关系模型的数据结构

关系模型与以往的模型不同, 它建立在严格的数学概念基础之上。其严格的定义将在第 2 章给出, 这里仅结合实例进行简单勾画。从用户观点看, 关系模型由一组关系组成, 每个关系的数据结构是一张规范化的二维表。例如, 表 1.2 所示的学生表即为一个典型的关系模型的数据结构。下面以该表为例, 介绍关系模型中的一些术语。

表 1.2 关系模型的数据结构示例: 学生表

学号 Sno	姓名 Sname	性别 Ssex	出生日期 Sbirthdate	主修专业 Smajor
20180001	李勇	男	2000-3-8	信息安全
20180002	刘晨	女	1999-9-1	计算机科学与技术
20180003	王敏	女	2001-8-1	计算机科学与技术
20180004	张立	男	2000-1-8	计算机科学与技术
20180005	陈新奇	男	2001-11-1	信息管理与信息系统
20180006	赵明	男	2000-6-12	数据科学与大数据技术
20180007	王佳佳	女	2001-12-7	数据科学与大数据技术

① 关系 (relation): 一个关系对应通常说的一张二维表, 如表 1.2 所示。

② 元组 (tuple): 表中的一行即为一个元组。

③ 属性: 表中的一列即为一个属性, 每列的名称即为属性名。如表 1.2 中共有 5 列, 对应 5 个属性 (学号, 姓名, 性别, 出生日期, 主修专业)。

④ 码: 又称为码键或键, 是表中的某一个属性或一组属性, 其值可以唯一确定一个元组。如表 1.2 中的属性“学号”可以唯一确定一个学生, 该属性也就成为本关系的码。

⑤ 域 (domain): 在表 1.2 中, 域表示某一属性的取值范围。例如, 属性“性别”的域是 (男, 女), “主修专业”的域是学生所在学院所有专业名称的集合。

⑥ 分量 (component): 元组中的一个属性值。例如, 表 1.2 中的“李勇”即为元组 (20180001, 李勇, 男, 2000-3-8, 信息安全) 的一个分量。

⑦ 关系模式: 对关系的描述, 一般表示为: 关系名 (属性 1, 属性 2, ..., 属性 n)。例如, 表 1.2 的关系可描述为: 学生 (学号, 姓名, 性别, 出生日期, 主修专业)。

关系模型要求关系必须是规范化 (normalization) 的, 即要求关系必须满足一定的规范条件, 这些规范条件中最基本的一条就是, 关系的每一个分量必须是一个不可分的数据项。也就是说, 不允许表中还有表。例如, 表 1.3 中“联系方式”是可分的数据项, 即“联系方式”又分

为“手机号”“Email”“微信号”三个数据项，所以表 1.3 不符合关系模型要求。

表 1.3 非规范化的表示例：表中有表

学号	姓名	性别	出生日期	主修专业	联系方式		
					手机号	Email	微信号
20180001	李勇	男	2000-3-8	信息安全	18301200745	liyong@qq.com	liyong@ruc
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

可以把关系术语和现实生活中的表格所使用的术语做一个粗略对比，如表 1.4 所示。

表 1.4 关系术语与现实生活中表格使用的术语对比

关系术语	现实生活中表格的术语
关系名	表名
关系模式	表头(表格的描述)
关系	(一张)二维表
元组	记录或行
属性	列
属性名	列名
属性值	列值
分量	一条记录中的一个列值
非规范关系	表中有表(大表中嵌有小表)

2. 关系模型的数据操纵与完整性约束

关系模型的数据操纵主要包括查询、插入、删除和更新数据，这些操作必须满足关系的完整性约束。关系的完整性约束包括实体完整性、参照完整性和用户定义的完整性三大类，其具体含义将在后续内容中介绍。

关系模型中的数据操纵是集合操作，操作对象和操作结果都是关系，即若干元组的集合；而层次模型和网状模型中的数据操纵则是单记录操作。另一方面，关系模型把存取路径向用户隐蔽起来，用户只要指出“干什么”或“找什么”，不必详细说明“怎么干”或“怎么找”，从而大大地增强了数据的独立性，提高了用户生产率。

3. 关系模型的优缺点

关系模型具有下列优点：

① 关系模型建立在严格的数学概念基础上。

② 关系模型的概念单一。无论实体还是实体之间的联系都用关系来表示，对数据的检索和更新结果也是关系，所以其数据结构简单、清晰，用户易懂易用。关系模型标准语言 SQL

简洁易用,推动了关系数据库的广泛应用。

③ 关系模型的存取路径对用户隐藏。它具有更强的数据独立性、更好的安全保密性,也简化了程序员的工作和数据库开发建立的工作。

关系模型的上述优点使其在诞生之后发展迅速,深受用户的喜爱。

当然,关系模型也有缺点,例如,由于存取路径对用户是隐蔽的,其查询效率往往不如层次模型和网状模型。为了提高性能,关系数据库管理系统必须对用户的查询请求进行优化,因此增加了开发关系数据库管理系统的难度。不过用户不必考虑这些系统内部的优化技术细节,数据库管理系统的查询优化器会自动选择优化的查询执行计划,为用户提供较高的查询性能。

1.2.7 数据库领域中不断涌现的数据模型

数据模型是数据库系统的核心,数据模型按照数据库系统的发展进程可分为层次模型、网状模型、关系模型、面向对象数据模型(object-oriented data model)、对象关系数据模型(object relational data model)、半结构化的XML(semi-structured extensible markup language)数据模型等。

随着大数据技术的发展和数据采集手段的便利多样,产生了众多需要管理和处理的不同类型的数据,如图数据、多媒体数据、网页数据等。为了管理这些数据,满足大数据应用的实际需要,人们研究和提出了多种新型数据结构和存储结构,并称其为新型数据模型。这些新型数据模型主要有键值(key value, KV)对数据模型、文档数据模型、图数据模型、时序数据模型、时空数据模型,流数据模型、多媒体数据模型等。

需要指出的是,相比于关系模型,这些模型按照数据模型应具备的三个基本要素(数据结构、数据操纵和完整性约束)来衡量是不严格的。例如,对这些数据的完整性约束就需要进一步研究和发展。

这些新型的数据结构或数据模型将在新技术篇中介绍部分内容。

数据模型小结

以上介绍了数据模型的初步概念,在数据库系统中针对不同的应用目的和对象采用了不同的数据模型,可以按照数据建模的过程将这些模型划分为概念模型和数据模型两个层次。概念模型是按用户的观点对数据和信息建模。数据模型是按计算机系统的观点对数据建模。数据模型是对现实世界客观对象的抽象,“抽象”是十分重要的概念,希望读者初步了解数据抽象的概念和方法。

不同的数据模型实际上提供了模型化数据和信息的不同工具。它们都应尽量满足三方面要求:一是能比较真实地模拟现实世界,二是容易为人所理解,三是便于在计算机上实现。

1.3 数据库系统的三级模式结构

考察数据库系统的结构可以有多种层次或角度。从数据库管理系统角度来看,数据库系统通常采用模式、外模式和内模式三级模式结构。这是数据库系统内部的体系结构。

1.3.1 数据库系统中模式的概念

在数据模型中有“类型”(或称型)和“值”的概念。型是指对某一类数据的结构和属性的说明,值是型的一个具体赋值。例如,学生(学号,姓名,性别,出生日期,主修专业)表示“学生”记录类型,而(20180003,王敏,女,2001-8-1,计算机科学与技术)则是该记录类型的一个记录值。

模式(schema)也称逻辑模式,是数据库中全体数据的逻辑结构和特征的描述,它仅仅涉及型的描述,不涉及具体的值。模式的一个具体值称为模式的一个实例(instance)。同一个模式可以有多个实例。

例如,在“学生选课”数据库模式中包含“学生”记录、“课程”记录和“学生选课”记录。现有一个具体的“学生选课”数据库实例,该实例包含了2020年学校中所有学生的记录(如果某校有10 000个学生,则有10 000条学生记录)、学校开设的所有课程的记录和所有学生选课的记录。

“2019年学生选课”数据库实例与“2020年学生选课”数据库实例是不同的。实际上“2020年学生选课”数据库实例也会随时间变化,因为在该年度可能会有学生退学或转专业等情况发生。不同时刻“学生选课”数据库实例是不同的和变化的,不变的是“学生选课”数据库模式。

模式是相对稳定的,而实例是相对变动的,因为数据库中的数据是在不断更新的。模式反映的是数据的结构及其联系,而实例反映的是数据库某一时刻的状态。

1.3.2 数据库系统的三级模式结构

虽然实际的数据库管理系统产品种类很多,它们支持不同的数据模型,使用不同的数据库语言,建立在不同的操作系统之上,数据的存储结构也各不相同,但它们在体系结构上通常都具有相同的特征,即采用三级模式结构并提供两级映像功能。

数据库系统的三级模式结构是指数据库系统是由模式、外模式和内模式三级构成,如图1.15所示。

1. 模式

模式是所有用户的公共数据视图。它是数据库系统模式结构的中间层,不涉及数据的物理存储细节和硬件环境,且与具体的应用程序、所使用的应用开发工具及高级程序设计语言无关。

模式实际上是数据库数据在逻辑级上的视图。一个数据库对应一个模式。数据库模式以某一种数据模型为基础,综合考虑了所有用户的需求,并将这些需求有机地结合成一个逻辑整体。定义模式时不仅要定义数据的逻辑结构,例如数据记录由哪些数据项构成,数据项的名称、类型、取值范围等,而且要定义数据之间的联系,以及与数据有关的安全性、完整性要求。

数据库管理系统提供模式数据定义语言来严格地定义模式。



图 1.15 数据库系统的三级模式结构

2. 外模式 (external schema)

外模式也称子模式 (subschema) 或用户模式, 它是数据库用户 (包括应用程序员和最终用户) 能够看见和使用的局部数据的逻辑结构和特征的描述。外模式是数据库用户的数据视图, 是与某一应用有关的数据的逻辑表示。

一个数据库可以有多个外模式。由于它是各个用户的数据视图, 如果不同的用户在应用需求、看待数据的方式、对数据保密的要求等方面存在差异, 则其外模式描述就是不同的。即使模式中的同一数据, 在不同的外模式中的结构、类型、长度、保密级别等都可能不同。此外, 同一外模式也可以为某一用户的多个应用系统所使用, 但一个应用程序只能使用一个外模式。

外模式是保证数据库安全性的一个有力措施。每个用户只能看见和访问所对应的外模式中的数据, 数据库中的其余数据是不可见的。

数据库管理系统提供外模式数据定义语言来严格地定义外模式。

3. 内模式 (internal schema)

内模式也称物理模式 (physical schema) 或存储模式 (storage schema), 一个数据库只有一个内模式。它是对数据物理结构和存储方式的描述, 是数据在数据库内部的组织方式。例如, 记录采用哪种方式存储, 是堆存储还是按照某个 (些) 属性值的升 (降) 序存储, 或按照属性值聚簇存储; 索引采用什么方式组织, 是 $B+$ 树索引还是哈希索引; 数据是否压缩存储, 是否加密; 数据的存储记录结构有何规定, 如采用定长结构或变长结构、一个记录不能跨物理页存储, 等等。

1.3.3 数据库的两级映像与数据独立性

数据库系统的三级模式是数据的三个抽象级别, 它把数据的具体组织留给数据库管理系统

管理,使用户能逻辑、抽象地处理数据,而不必关心数据在计算机中的具体表示方式与存储方式。为了能够在系统内部实现这三个抽象层次的联系和转换,数据库管理系统在这三级模式之间提供了两级映像:外模式/模式映像和模式/内模式映像。

正是这两级映像保证了数据库系统中的数据能够具有较强的逻辑独立性和物理独立性。

1. 外模式/模式映像

前已提及,模式描述的是数据的全局逻辑结构,外模式描述的是数据的局部逻辑结构。对于同一个模式,可以有任意多个外模式。对于每一个外模式,数据库系统都有一个外模式/模式映像来定义该外模式与模式之间的对应关系。这些映像定义通常包含在各自外模式的描述中。

当模式改变时(如增加新的关系、新的属性,改变属性的数据类型等),由数据库管理员对各个外模式/模式的映像做相应改变,可以使外模式保持不变。应用程序是依据数据的外模式编写的,因而应用程序不必修改,保证了数据与程序的逻辑独立性,简称数据的逻辑独立性。

2. 模式/内模式映像

数据库只有一个模式,也只有一个内模式,所以模式/内模式映像是唯一的,它定义了数据全局逻辑结构与存储结构之间的对应关系。例如,说明逻辑记录和字段在内部是如何表示的。该映像定义通常包含在模式描述中。当数据库的存储结构改变时(如选用了另一种存储结构),由数据库管理员对模式/内模式映像做相应改变,可以使模式保持不变,因而应用程序也不必改变,保证了数据与程序的物理独立性,简称数据的物理独立性。

数据库系统的三级模式结构小结

在数据库的三级模式结构,其中,模式(即全局逻辑结构)是数据库的核心与关键,它独立于数据库的其他层次。因此设计数据库模式结构时应首先确定数据库的逻辑模式。

内模式依赖于数据库的全局逻辑结构,但独立于数据库的用户视图(即外模式),也独立于具体的存储设备。它将全局逻辑结构中所定义的数据结构及其联系按照一定的物理存储策略进行组织,以达到较好的时间与空间效率。

外模式面向具体的应用程序,它定义在逻辑模式之上,但独立于存储模式和存储设备。当应用需求发生较大变化,相应的外模式不能满足其视图要求时,该外模式就得做相应改动。所以设计外模式时应充分考虑到应用的扩充性。

特定的应用程序是在外模式描述的数据结构上编制的,它依赖于特定的外模式,与数据库的模式和存储结构独立。不同的应用程序有时可以共用同一个外模式。数据库的两级映像保证了数据库外模式的稳定性,从而从底层保证了应用程序的稳定性,除非应用需求本身发生变化,否则应用程序一般不需修改。数据与程序之间的独立性,使得数据的定义和描述可以从应用程序中分离出去。另外,数据的组织和存取交由数据库管理系统负责,简化了应用程序的编制,大大减少了应用程序的开发和维护成本。

1.4 数据库系统的组成

在 1.1 节中已经讲到,数据库系统是指引入数据库后的计算机系统,一般由数据库、数据库管理系统(及其应用开发工具)、应用系统和数据库管理员组成(参见图 1.1)。本节从支撑数据库系统的硬件平台、软件平台及人员三方面对数据库系统的组成进行介绍。

1. 硬件平台

数据库存放在计算机存储设备中。从数据库技术的发展来看,硬件平台中存储器与处理器技术的升级推动了数据库技术从磁盘数据库到内存数据库的技术升级。特别是随着大数据应用的日益广泛,海量存储设备与高速处理器的硬件特性成为新型数据库存储引擎和查询引擎设计的重要因素。

2. 软件平台

支撑数据库系统的软件平台主要包括操作系统、数据库管理系统、开发应用系统的高级语言及其编译系统、各种各样的应用开发工具,以及为特定应用背景开发的数据库应用系统等。它们共同为数据库系统的开发和应用提供了良好的软件生态环境。

3. 人员

开发、管理和使用数据库系统的人员主要包括数据库管理员、系统分析员和数据库设计员、应用程序员和最终用户。不同角色的人员各司其职,涉及不同的数据抽象级别,具有不同的数据视图,如图 1.16 所示。




图 1.16 数据库系统各种人员的数据视图

(1) 数据库管理员(DBA)

其主要职责包括：

① 设计与定义数据库。数据库管理员必须参与数据库设计的全过程,与最终用户、应用

程序员、系统分析员密切结合,设计概念模式、数据库模式以及各个应用的外模式;还要熟悉所使用的数据库管理系统产品,决定数据库的存储结构和存取策略,设计数据库的内模式。

② 帮助最终用户使用数据库系统。数据库管理员要担负起培训最终用户的责任,并负责解答最终用户日常使用数据库系统时遇到的问题。

③ 负责数据库系统的运维工作。数据库管理员负责监视数据库系统的运行情况,及时处理运行过程中出现的问题,控制不同用户访问数据库的权限,收集数据库的审计信息,保证数据库的安全性和完整性。

④ 改进和重组数据库系统,调优数据库系统的性能。数据库管理员负责监视、分析数据库系统的性能,包括空间利用率和处理效率。虽然在系统设计时已经充分考虑了性能要求,但性能的好坏只能通过实际运行结果来检验,所以数据库管理员必须对运行状况进行记录、统计和分析,并根据实际应用环境不断改进数据库设计,例如根据实际情况修改某些系统参数和环境变量值来改善系统性能。另一方面,数据库运行过程中会不断地插入、删除、修改数据,这样在一段时间后必然会影响数据的物理布局,导致系统性能下降,因此数据库管理员要定期或按一定的策略对数据库进行重组。

⑤ 转储与恢复数据库。为了减少硬件、软件或人为故障对数据库系统的破坏,数据库管理员必须定义和实施适当的后援和恢复策略。例如,周期性地转储数据、维护日志文件等。一旦系统发生故障,数据库管理员必须能够在最短时间内把数据库恢复到某一正确状态,并且尽可能不影响或少影响计算机系统其他部分的正常运行。

⑥ 重构数据库。当用户的应用需求增加或改变时,数据库管理员需要对数据库进行较大的改造,包括修改内模式或模式,即重新构造数据库。

(2) 系统分析员和数据库设计员

其主要职责为应用系统的需求分析与规范说明,进行总体设计。因此他们必须与用户及数据库管理员相结合,进行数据库各级模式的设计,确定系统的软硬件配置。

(3) 应用程序员

其主要职责为以外模式为基础开发应用系统,编制具体的应用程序。数据库的两级映像保证了他们不必考虑数据的存储细节。

(4) 最终用户

其主要职责为具体操作应用系统,通过应用系统客户端的用户界面使用数据库以完成业务活动。

* 1.5 数据库系统的体系结构

根据计算机的系统结构,从数据库最终用户角度来看,数据库系统可分为集中式数据库系统、客户-服务器(浏览器/应用服务器/数据库服务器)数据库系统、并行数据库系统、分布式数据库系统和云计算环境下的数据库系统(云数据库系统)等。这是数据库系统外部的体系

结构。

1. 集中式数据库系统

集中式数据库系统的数据库管理系统、数据库和应用程序都在一台计算机上。在小型机和大型机上的集中式数据库系统一般是多用户系统,即多个用户通过各自的终端运行不同的应用系统,共享数据库。微型计算机上的数据库系统一般是单用户的。

2. 客户-服务器数据库系统

在客户-服务器数据库系统中,数据库管理系统、数据库驻留在服务器上,而应用程序放置在客户机上(微型计算机或工作站),客户机和服务器通过网络进行通信。在这种结构中,客户机负责提供业务数据处理流程和应用程序界面,当要存取数据库中的数据时就向服务器发出请求,服务器接收客户机的请求后进行处理,并将客户要求的数据返回给客户机。

随着互联网技术的应用,客户-服务器两层结构已经发展为三层或多层结构。三层结构一般是指浏览器/应用服务器/数据库服务器结构。用户界面采用统一的浏览器方式,应用服务器上安装应用系统或应用模块,数据库服务器上安装数据库管理系统和数据库。两层或三层结构对数据库管理系统的功能进行了合理的分配,减轻了数据库服务器的负担,从而使服务器有更多的能力完成事务处理和数据访问控制,支持更多的用户,提高系统的性能。

3. 并行数据库系统

并行数据库系统是在并行计算机上运行的具有并行处理能力的数据库系统,是数据库技术与并行计算技术相结合的产物。并行计算机系统有共享内存型、共享磁盘型、非共享型以及混合型等。并行计算技术利用多处理机并行处理产生的规模效益来提高系统的整体性能。并行数据库系统发挥了多处理机的优势,采用并行查询处理技术和并行数据分布与管理技术,具有高性能、高可用性、高扩展性等优点。

4. 分布式数据库系统

分布式数据库系统是指数据库中的数据在逻辑上是一个整体,但物理地分布在计算机网络的不同节点上。网络中的每个节点独立处理本地数据库中的数据(称为场地自治),执行局部应用;也可以执行全局应用,即通过网络通信系统同时存取和处理多个节点上数据库的数据。

分布式数据库系统适用于企业部门分布的组织结构,可以降低费用,提高系统的可靠性和可用性,具有良好的可扩展性。

5. 云数据库系统

近年来大数据应用飞速发展,数据量激增,用户对性能的要求越来越高,并发用户数在峰值和低谷时差距明显,这使得企业自己运营和维护数据库的成本越来越高。如果按峰值配置设备,平时会造成很大的浪费,但如果按低谷值配置设备,又会出现无法应对峰值的情形。于是伴随云计算(cloud computing)技术的发展,云数据库系统应运而生。

云数据库系统把数据库部署或虚拟化在云计算环境下,通过计算机网络以服务的形式提供数据库的功能,包括数据存储、数据更新、查询处理、事务管理等。早期的云数据库主要运行在单个节点上,该节点有多处理器、大内存和大磁盘容量。现在的云数据库是运行在集群上的

并行数据库系统,能够较好地进行动态伸缩、按需分配计算资源和存储资源。但是,云数据库存储的安全可信、隐私保护等问题不可忽视,亟待研究解决。

本章小结

本章概述了数据库的基本概念,并通过对数据管理技术进展情况的介绍阐述了数据库技术产生和发展的背景,说明了数据库系统的优点。

数据模型是数据库系统的核心和基础。本章简要介绍了概念模型、组成数据模型的三要素(数据结构、数据操纵、完整性约束)和三种数据模型(层次模型、网状模型、关系模型)。

本章介绍了数据库系统的三级模式和两级映像,这样的系统架构保证了数据库系统能够具有较强的逻辑独立性和物理独立性。

本章还介绍了数据库系统的组成,使读者了解数据库系统不仅是一个计算机系统,而且是一个人机系统(man-machine system)。最后根据计算机的系统结构,本章简要介绍了集中式数据库系统、客户-服务器(浏览器/应用服务器/数据库服务器)数据库系统、并行数据库系统、分布式数据库系统和云数据库系统等。

习题 1

1. 试述数据、数据库、数据库管理系统、数据库系统的概念。
2. 试述文件系统与数据库系统之间的区别和联系。
3. 分别举出适合用文件系统的应用例子,以及适合用数据库系统的应用例子。
4. 试述数据库系统的特点。
5. 数据库管理系统的主要功能有哪些?
6. 什么是概念模型?试述概念模型的作用。
7. 定义并解释概念模型中以下术语:
实体,实体型,实体集,实体之间的联系
8. 试述数据模型的概念、作用及其包含的三个要素。
9. 试述层次模型的概念,举出三个层次模型的实例。
10. 试述网状模型的概念,举出三个网状模型的实例。
11. 试述网状数据库、层次数据库的优缺点。
12. 试述关系模型的概念,定义并解释以下术语:
关系,属性,域,元组,码,分量,关系模式
13. 试述关系模型的优缺点。
14. 试述数据库系统的三级模式结构,并说明这种结构的优点是什么。
15. 试述数据与程序的物理独立性和逻辑独立性。为什么数据库系统具有较强的数据与程序的独立性?
16. 试述数据库系统的组成。

第1章实验 实验准备

实验准备主要包括关系数据库管理系统选择、实验环境配置和实验数据准备等工作。

推荐使用国产的金仓数据库管理系统,例如金仓数据库 KingbaseES。也可以使用任何一种关系数据库管理系统产品或开源数据库管理系统。

建议学生亲自安装选用的关系数据库管理系统产品,观察数据库安装过程,记录和理解安装配置参数,熟悉数据库管理系统的客户端图形管理工具。

我们在《数据库系统概论(第6版)习题解析与实验指导》(以下简称《概论辅导书》)中详细介绍了各章实验内容与实验目的,并提供有实验报告样例等,供读者上机实验参考。

参考文献 1

[1] BRODIE M L, SCHMIDT J W. Final report of the ANSI/X3/SPARC DBS-SG relational database task group [J]. ACM SIGMOD Record, 1982, 12(4):1-62.

[2] ANSI/X3/SPARC Study Group on Data Base Management Systems[R]. Interim Report, FDT-ACM SIGMOD bulletin, 1975, 7(2).

文献[1][2]介绍了 ANSI/X3/SPARC 及数据库系统三级模式结构。

[3] 萨师煊,王珊.数据库系统概论[M].2版.北京:高等教育出版社,1991.

文献[3]中第2、3章比较详细地介绍了层次数据库系统和网状数据库系统的基本概念和一般原理。

[4] BACHMAN C W, WILLIAMS S B. A general purpose programming system for random access memories[C]. Proceedings of the Fall Joint Computer Conference, AFIPS'64, 1964: 411-422.

文献[4]描述的是 Charles Bachman 在第一个商业数据库管理系统的开发期间进行的网状数据模型早期研究工作。

[5] BACHMAN C W. Data structure diagrams[J]. ACM SIGMIS Database: the DATABASE for Advances in Information Systems, 1969, 1(2): 4-10.

文献[5]最早提出了用数据结构简图表示数据之间联系的思想。

[6] BACHMAN C W. The Programmer as Navigator[J]. CACM-Communications of the ACM, 1973, 16(11): 635-638.

Bachman 的成就使他于 1973 年荣获了 ACM 最高荣誉——图灵奖。他在图灵奖演说中把数据库看作基本资源,把程序设计者看作数据库中的领航员。

[7] BACHMAN C W. The data structure set model[C]. Proceedings of the 1974 ACM SIGMOD Workshop on Data Description, Access and Control: Data Structure Set Versus Relation, 1974, 2.

在 1974 年支持和反对关系模型研究的讨论中, Bachman 持反对态度。

[8] Data Base Task Group Report to the CODASYL Programming Language Committee[J], ACM SIGMIS Database: the DATABASE for Advances in Information Systems, 1971, 2(2).

CODASYL 的数据库任务组(DBTG)对网状数据库系统进行了系统研究,在本报告中提出了模式数据定义语言、子模式数据定义语言和嵌入 COBOL 的数据操纵语言,以后又发表了多篇报告。

本章知识点讲解微视频:



数据库发展概述



数据库的4个基本概念



数据建模与数据模型



数据库的三级模式结构

关系模型应用数学方法来处理数据库中的数据。1962年 CODASYL 发表的“信息代数”最早提出将这类方法用于数据处理,1968年 David Child 在 IBM 7090 机上实现了集合论数据结构,但系统、严格地提出关系模型的是 Edgar F. Codd。

1970年,Edgar F. Codd 在美国计算机学会(ACM)会刊上发表了题为 *A Relational Model of Data for Large Shared Data Banks* 的论文,开创了数据库系统的新纪元。1983年,该论文被 ACM 列为 1958 年以来的 1/4 世纪中具有里程碑意义的 25 篇研究论文之一。此后,Edgar F. Codd 又陆续发表了多篇论文,奠定了关系数据库的理论基础。

20 世纪 70 年代末,关系方法的理论研究和软件系统的研制紧密结合,均取得了丰硕的成果。例如,IBM 公司的 San Jose 实验室在 IBM 370 系列机上研制的关系数据库实验系统 System R 历时 6 年获得成功。1981 年,IBM 公司宣布具有 System R 全部特征的新的数据库软件产品 SQL/DS 问世。

与 System R 同期,1973 年美国加州大学伯克利分校的 Michael Stonebraker 和 Eugene Wong 研制了 INGRES 关系数据库实验系统,并由 INGRES 公司发展成为 INGRES 数据库产品。在 INGRES 的基础上,20 世纪 80 年代中期 PostgreSQL 系统发布并成功开放其源代码。

在此期间 Oracle 公司成立,1978 年发布了 Oracle 1.0,以后短短十几年中 Oracle 产品不断成熟,Oracle 公司也逐渐发展成为著名的数据库软件及服务供应商。

此后数据库领域又涌现出许多优秀的关系数据库产品,关系数据库系统逐渐从实验室走入社会,得到了广泛的应用和快速的发展。

本章导读

本章基于第一章对关系模型及其基本术语的介绍,进一步深入讲解关系模型的有关内容。

本章按照数据模型的三要素,介绍关系模型的数据结构及形式化定义、关系操作和关系数据语言的大致分类、关系的三类完整性约束。希望读者能牢固掌握关系模型三个组成部分的内涵,为学习 SQL 和数据库安全性与完整性打下基础。

本章还讲解了关系代数和关系演算。关系代数用对关系的运算来表达查询要求,关系代数