

关系模型应用数学方法来处理数据库中的数据。1962年 CODASYL 发表的“信息代数”最早提出将这类方法用于数据处理,1968年 David Child 在 IBM 7090 机上实现了集合论数据结构,但系统、严格地提出关系模型的是 Edgar F. Codd。

1970年,Edgar F. Codd 在美国计算机学会(ACM)会刊上发表了题为 *A Relational Model of Data for Large Shared Data Banks* 的论文,开创了数据库系统的新纪元。1983年,该论文被 ACM 列为 1958 年以来的 1/4 世纪中具有里程碑意义的 25 篇研究论文之一。此后,Edgar F. Codd 又陆续发表了多篇论文,奠定了关系数据库的理论基础。

20 世纪 70 年代末,关系方法的理论研究和软件系统的研制紧密结合,均取得了丰硕的成果。例如,IBM 公司的 San Jose 实验室在 IBM 370 系列机上研制的关系数据库实验系统 System R 历时 6 年获得成功。1981 年,IBM 公司宣布具有 System R 全部特征的新的数据库软件产品 SQL/DS 问世。

与 System R 同期,1973 年美国加州大学伯克利分校的 Michael Stonebraker 和 Eugene Wong 研制了 INGRES 关系数据库实验系统,并由 INGRES 公司发展成为 INGRES 数据库产品。在 INGRES 的基础上,20 世纪 80 年代中期 PostgreSQL 系统发布并成功开放其源代码。

在此期间 Oracle 公司成立,1978 年发布了 Oracle 1.0,以后短短十几年中 Oracle 产品不断成熟,Oracle 公司也逐渐发展成为著名的数据库软件及服务供应商。

此后数据库领域又涌现出许多优秀的关系数据库产品,关系数据库系统逐渐从实验室走入社会,得到了广泛的应用和快速的发展。

本章导读

本章基于第一章对关系模型及其基本术语的介绍,进一步深入讲解关系模型的有关内容。

本章按照数据模型的三要素,介绍关系模型的数据结构及形式化定义、关系操作和关系数据语言的大致分类、关系的三类完整性约束。希望读者能牢固掌握关系模型三个组成部分的内涵,为学习 SQL 和数据库安全性与完整性打下基础。

本章还讲解了关系代数和关系演算。关系代数用对关系的运算来表达查询要求,关系代数

表达式是关系数据库管理系统查询优化中代数优化的依据,读者应掌握关系代数表达查询的方法。关系演算以数理逻辑中的谓词演算为基础,用谓词来表达查询要求。本章讲解了元组关系演算语言 ALPHA 和域关系演算语言 QBE,希望读者基本掌握关系演算语言的概念和使用方法,并通过习题加强练习。

2.1 关系模型的数据结构及形式化定义

本书第1章1.2.6小节非形式化地介绍了关系模型的基本概念。由于关系模型是建立在集合代数基础上的,本节从集合论角度给出关系数据结构的形式化定义,以及关系模式的形式化表示,并简要介绍关系数据库和关系模型的存储结构。

2.1.1 关系

关系模型的数据结构非常简单,只包含单一的数据结构——关系。在用户看来,关系模型中数据的逻辑结构是一张二维表。

关系模型的数据结构虽然简单却能够表达丰富的语义,描述现实世界的实体以及实体间的各种联系。也就是说,在关系模型中,现实世界的实体以及实体间的各种联系均用单一的结构类型,即关系来表示。

1. 域

定义 2.1 域是一组具有相同数据类型的值的集合。

例如,自然数、整数、实数、长度小于 25 B 的变长字符串集合、 $\{0,1\}$ 、 $\{\text{男},\text{女}\}$ 、 $0\sim 100$ 之间的正整数等,都可以是域。

2. 笛卡儿积

笛卡儿积(Cartesian product)是域上的一种集合运算。

定义 2.2 给定一组域 $D_1, D_2, \dots, D_n$, 允许其中某些域是相同的, $D_1, D_2, \dots, D_n$ 的笛卡儿积为

$$D_1 \times D_2 \times \dots \times D_n = \{(d_1, d_2, \dots, d_n) \mid d_i \in D_i, i=1, 2, \dots, n\}$$

其中,每一个元素 $(d_1, d_2, \dots, d_n)$ 叫作一个 n 元组(n -tuple),简称元组。元组中的每一个值 d_i 叫作一个分量。

一个域允许的不同取值个数称为这个域的基数(cardinal number)。

若 $D_i (i=1, 2, \dots, n)$ 为有限集,其基数为 $m_i (i=1, 2, \dots, n)$, 则 $D_1 \times D_2 \times \dots \times D_n$ 的基数 M 为

$$M = \prod_{i=1}^n m_i$$

笛卡儿积可表示为一张二维表。表中的每一行对应一个元组,表中的每一列的值来自一个域。例如,给出三个域:

$$D_1 = \text{导师 (SUPERVISOR)} = \{\text{张清玫, 刘逸}\}$$

$$D_2 = \text{专业 (MAJOR)} = \{\text{计算机科学与技术, 信息管理与信息系统}\}$$

$$D_3 = \text{研究生 (POSTGRADUATE)} = \{\text{李勇, 刘晨, 王敏}\}$$

则 D_1 、 D_2 、 D_3 的笛卡儿积如下:

$$D_1 \times D_2 \times D_3 = \{(\text{张清玫, 计算机科学与技术, 李勇}), (\text{张清玫, 计算机科学与技术, 刘晨}),$$

$$(\text{张清玫, 计算机科学与技术, 王敏}), (\text{张清玫, 信息管理与信息系统, 李勇}),$$

$$(\text{张清玫, 信息管理与信息系统, 刘晨}), (\text{张清玫, 信息管理与信息系统, 王敏}),$$

$$(\text{刘逸, 计算机科学与技术, 李勇}), (\text{刘逸, 计算机科学与技术, 刘晨}),$$

$$(\text{刘逸, 计算机科学与技术, 王敏}), (\text{刘逸, 信息管理与信息系统, 李勇}),$$

$$(\text{刘逸, 信息管理与信息系统, 刘晨}), (\text{刘逸, 信息管理与信息系统, 王敏})\}$$

其中,“(张清玫, 计算机科学与技术, 李勇)”“(张清玫, 计算机科学与技术, 刘晨)”等都是元组,“张清玫”“计算机科学与技术”“李勇”“刘晨”等都是元组的分量。

该笛卡儿积的基数为 $2 \times 2 \times 3 = 12$ 。也就是说, $D_1 \times D_2 \times D_3$ 共有 $2 \times 2 \times 3 = 12$ 个元组。这 12 个元组可列成一张二维表, 如表 2.1 所示。

表 2.1 笛卡儿积示例

导师 SUPERVISOR	专业 MAJOR	研究生 POSTGRADUATE
张清玫	计算机科学与技术	李勇
张清玫	计算机科学与技术	刘晨
张清玫	计算机科学与技术	王敏
张清玫	信息管理与信息系统	李勇
张清玫	信息管理与信息系统	刘晨
张清玫	信息管理与信息系统	王敏
刘逸	计算机科学与技术	李勇
刘逸	计算机科学与技术	刘晨
刘逸	计算机科学与技术	王敏
刘逸	信息管理与信息系统	李勇
刘逸	信息管理与信息系统	刘晨
刘逸	信息管理与信息系统	王敏

3. 关系

一般来说, 在关系模型中 $D_1, D_2, \dots, D_n$ 的笛卡儿积是没有实际语义的, 只有它的某个真子集才有实际含义。

例如,可以发现表 2.1 的笛卡儿积中许多元组是没有意义的。因为在学校中一个专业方向有多个导师,而一个导师只在一个专业方向带研究生;一个导师可以带多个研究生,而一个研究生只有一个导师,学习某一个专业。因此,表 2.1 中的一个子集才是有意义的,可以表示导师与研究生的关系。把该关系取名为 SMP,如表 2.2 所示,李勇和刘晨是计算机科学与技术专业张清玫老师的研究生,王敏是信息管理与信息系统专业刘逸老师的研究生。

表 2.2 导师-研究生关系 SMP

导师 SUPERVISOR	专业 MAJOR	研究生 POSTGRADUATE
张清玫	计算机科学与技术	李勇
张清玫	计算机科学与技术	刘晨
刘逸	信息管理与信息系统	王敏

关系 SMP 包含的属性为 SUPERVISOR、MAJOR 和 POSTGRADUATE,则其关系模式可以表示为

SMP(SUPERVISOR, MAJOR, POSTGRADUATE)

下面给出关系及关系模式的形式化定义和相关概念。

定义 2.3 给定一组域 $D_1, D_2, \dots, D_n$, 允许其中某些域是相同的, $D_1, D_2, \dots, D_n$ 的笛卡儿积 $D_1 \times D_2 \times \dots \times D_n$ 的子集称为这组域上的关系, 表示为

$$R(D_1, D_2, \dots, D_n)$$

这里 R 表示关系名, n 是关系的目或度(degree)。

当 $n=1$ 时, 称该关系为一元关系(unary relation)或单元关系、单目关系。

当 $n=2$ 时, 称该关系为二元关系(binary relation)或二目关系。

关系中的每个元素是关系中的元组, 通常用 t 表示。

关系是笛卡儿积的有限子集, 所以关系是一张二维表, 表的每一行对应一个元组, 表的每一列对应一个域。由于域可以相同, 为了加以区分, 必须对每一列起一个名字, 称为属性。 n 目关系必有 n 个属性。

例如, SMP(SUPERVISOR, MAJOR, POSTGRADUATE)有三个属性, 是一个三目关系。

(张清玫, 计算机科学与技术, 李勇)、(张清玫, 计算机科学与技术, 刘晨)和(刘逸, 信息管理与信息系统, 王敏)是 SMP 关系的三个元组。

关系可以有三种类型: 基本关系(通常又称为基本表或基表)、查询结果和视图。其中, 基本关系是实际存在的表, 它是实际存储数据的逻辑表示; 查询结果是查询执行产生的结果对应的临时表; 视图是由基本表或其他视图导出的虚表, 不存储实际数据。

按照定义 2.2, 关系可以是一个无限集合。例如, 某个域是整数, 而整数是个无限集合。此外, 在数学上组成笛卡儿积的域不满足交换律, 所以按照数学定义, $(d_1, d_2, \dots, d_n) \neq (d_2,$

$d_1, \dots, d_n$)。因此,当关系作为数据模型的数据结构时,需要给予如下的限定和扩充。

① 无限关系在数据库系统中是无意义的。因此,限定关系模型中的关系必须是有限集合。

② 通过为关系的每个列附加一个属性名的方法取消关系属性的有序性,使得列的次序可以任意交换:

$$(d_1, d_2, \dots, d_i, d_j, \dots, d_n) = (d_1, d_2, \dots, d_j, d_i, \dots, d_n) \quad (i, j = 1, 2, \dots, n)$$

因此,基本关系具有以下 6 条性质。

① 列是同质的(homogeneous),即每一列中的分量是同一类型的数据,来自同一个域。

② 不同的列可出自同一个域,称其中的每一列为一个属性,不同的属性要给予不同的属性名。例如,在上面的例子中,也可以只给出两个域:

人(PERSON) = {张清玫,刘逸,李勇,刘晨,王敏}

专业(MAJOR) = {计算机科学与技术,信息管理与信息系统}

SMP 关系的导师属性和研究生属性都是从 PERSON 域中取值。为了避免混淆,必须给这两个属性取不同的属性名,而不能直接使用域名。因此,定义导师属性名为 SUPERVISOR,研究生属性名为 POSTGRADUATE。

③ 列的顺序无所谓,即列的次序可以任意交换。由于列顺序是无关紧要的,因此在许多实际的关系数据库产品中增加新属性时,永远是将其插至最后一列。

④ 任意两个元组的码不能取相同的值。

⑤ 行的顺序无所谓,即行的次序可以任意交换。

⑥ 分量必须取原子值,即每一个分量都必须是不可分的数据项。

关系模型要求关系必须满足一定的规范条件,其中最基本的一条就是元组的每一个分量必须是一个不可分的数据项。仍以导师-研究生关系为例,表 2.3 虽然很好地表达了两之间的一对多联系,即一个导师可以指导多个研究生,但是由于属性“POSTGRADUATE”中分量取了两个值“PG1”“PG2”,不符合规范化的要求,因此这样的关系在关系数据库中是不允许的。直观地描述,表 2.3 中还有一个小表,不符合规范化的条件。

表 2.3 非规范化关系

SUPERVISOR	MAJOR	POSTGRADUATE	
		PG1	PG2
张清玫	计算机科学与技术	李勇	刘晨
刘逸	信息管理与信息系统	王敏	

小表

规范化的关系简称为范式(normal form, NF),将在第 6 章关系数据理论中做进一步讲解。

2.1.2 关系模式

第 1 章 1.3.1 小节已经简单介绍了数据库系统中模式的概念。强调了在数据库中要区分数

据模型的型和值。在关系模型中,关系是元组的集合,关系是值;关系模式是对关系的描述,关系模式是型。

那么关系模式需要描述关系的哪些方面呢?

首先,关系模式必须描述关系元组集合的结构,即它由哪些属性构成,这些属性来自哪些域,以及属性与域之间的映像关系。

其次,关系模式要描述关系的完整性约束。现实世界随着时间在不断地变化,因而在不同的时刻关系模式所描述的关系也会不断变化。例如,在“学生”关系中,2020年某校的在校生与2019年就不同。但是,现实世界的许多已有事实和规则限定了关系模式所有可能的关系必须满足一定的完整性约束条件。这些约束条件或者通过对属性取值范围进行限定来描述,或者通过属性与属性之间的相互关联和相互约束反映出来。

定义 2.4 关系的描述称为**关系模式**(relation schema)。它可以形式化地表示为

$$R(U, D, \text{DOM}, F)$$

其中 R 为关系名, U 为组成该关系的属性的属性名集合, D 为 U 中属性所来自的域, DOM 为属性向域的映像集合, F 为属性间数据依赖关系的集合。

属性间的数据依赖将在第6章讨论,本章中关系模式仅涉及关系名、属性名、域名、属性向域的映像4部分,即 $R(U, D, \text{DOM})$ 。

例如,在上面例子中,由于导师和研究生出自同一个域——人:

$$\text{DOM}(\text{SUPERVISOR}) = \text{DOM}(\text{POSTGRADUATE}) = \text{PERSON}$$

所以要取不同的属性名,并在模式中定义属性向域的映像,即说明它们分别出自哪个域。

关系模式通常简记为

$$R(U)$$

或

$$R(A_1, A_2, \dots, A_n)$$

其中 R 为关系名, $A_1, A_2, \dots, A_n$ 为属性名;而域名及属性向域的映像则常直接说明为属性的类型、长度。

若关系模式中的某一个属性或一组属性的值能唯一地标识一个元组,而它的真子集不能唯一地标识一个元组,则称该属性或属性组为**候选码**(candidate key)。

若一个关系有多个候选码,则选定其中一个为**主码**(primary key),或称**主键**。

例如,在导师-研究生关系 $\text{SMP}(\text{SUPERVISOR}, \text{MAJOR}, \text{POSTGRADUATE})$ 中,假设研究生不会重名(这在实际生活中可能做不到,这里只是为了举例方便),则 POSTGRADUATE 属性的每一个值都唯一地标识了一个元组,因此可以作为 SMP 关系的主码,用在其名称下加下划线表示。

候选码的诸属性称为主属性(prime attribute)。不包含在任何候选码中的属性称为非主属性(non prime attribute)或非码属性(non-key attribute)。

在最简单的情况下, 候选码只包含一个属性。在最极端的情况下, 关系模式的所有属性是这个关系模式的候选码, 称为全码(all-key)。

关系是关系模式在某一时刻的状态或内容。关系模式是静态的、稳定的, 而关系是动态的、随时间不断变化的, 这是因为关系操作在不断地更新着数据库中的数据。例如, “学生”关系模式在不同的学年是相同的, 而“学生”关系是不同的。在实际工作中, 人们常常把关系模式和关系都笼统地称为关系, 这可以根据上下文加以区别, 希望读者注意。

2.1.3 关系数据库

支持关系模型的数据库系统称为关系数据库系统。在关系模型中, 实体以及实体间的联系都是用关系来表示的。例如, “学生”实体、“课程”实体、学生与课程之间选修课程的多对多联系都可以分别用一个关系模式来描述。

“学生”关系模式: Student(Sno, Sname, Ssex, Sbirthdate, Smajor), 包括学号、姓名、性别、出生日期和主修专业等属性。

“课程”关系模式: Course(Cno, Cname, Ccredit, Cpno), 包括课程号、课程名、学分、先修课(直接先修课)等属性。

“学生选课”关系模式: SC(Sno, Cno, Grade, Semester, Teachingclass), 包括学号、课程号、成绩、开课学期、教学班等属性。

在一个关系数据库中, 某一时刻所有关系模式对应的关系的集合构成一个关系数据库。例如如图 2.1 就是一个“学生选课”数据库示例, 该数据库包含 3 个关系。

关系数据库也有类型和值之分。关系数据库的类型就是关系数据库中所有关系模式的集合, 是对关系数据库的描述, 通常称为关系数据库模式。关系数据库的值是这些关系模式在某一时刻对应的关系的集合, 通常称为关系数据库。

2.1.4 关系模型的存储结构

关系模型是关系数据的逻辑结构, 用关系数据定义语言描述, 例如第 3 章将介绍的关系数据库标准语言 SQL。

支持关系模型的关系数据库管理系统(relational database management system, RDBMS)将以一定的组织方式存储和管理数据, 即设计和实现关系模型的存储结构, 这是关系数据库管理系统的重要职责之一。

例如, 有的关系数据库管理系统中一个表对应一个操作系统文件, 将物理数据组织的许多任务交给操作系统完成; 有的关系数据库管理系统则从操作系统那里申请若干个大的文件, 自己划分文件空间, 组织表、索引等存储结构并进行存储管理。

本书第 9 章将专门讲解关系数据库存储管理, 重点介绍基于磁盘的数据库的组织与存储。

Student

学号 Sno	姓名 Sname	性别 Ssex	出生日期 Sbirthdate	主修专业 Smajor
20180001	李勇	男	2000-3-8	信息安全
20180002	刘晨	女	1999-9-1	计算机科学与技术
20180003	王敏	女	2001-8-1	计算机科学与技术
20180004	张立	男	2000-1-8	计算机科学与技术
20180005	陈新奇	男	2001-11-1	信息管理与信息系统
20180006	赵明	男	2000-6-12	数据科学与大数据技术
20180007	王佳佳	女	2001-12-7	数据科学与大数据技术

(a)

Course

课程号 Cno	课程名 Cname	学分 Ccredit	先修课 Cpno
81001	程序设计基础与C语言	4	
81002	数据结构	4	81001
81003	数据库系统概论	4	81002
81004	信息系统概论	4	81003
81005	操作系统	4	81001
81006	Python语言	3	81002
81007	离散数学	4	
81008	大数据技术概论	4	81003

(b)

SC

学号 Sno	课程号 Cno	成绩 Grade	开课学期 Semester	教学班 Teachingclass
20180001	81001	85	20192	81001-01
20180001	81002	96	20201	81002-01
20180001	81003	87	20202	81003-01
20180002	81001	80	20192	81001-02
20180002	81002	98	20201	81002-01
20180002	81003	71	20202	81003-02
20180003	81001	81	20192	81001-01
20180003	81002	76	20201	81002-02
20180004	81001	56	20192	81001-02
20180004	81002	97	20201	81002-02
20180005	81003	68	20202	81003-01

(c)

图 2.1 “学生选课”数据库示例

2.2 关系操作

关系模型给出了关系操作能力的说明，但不关系数据库管理系统语言做具体的语法要求，也就是说不同的关系数据库管理系统可以定义和开发不同的语言来实现关系操作。