

机器学习自动识别敏感数据；异常检测，即监视数据库活动并检测漏洞；访问控制，即通过自动估计不同的数据访问操作来避免数据泄漏；深度学习，以挖掘用户行为并识别 SQL 注入攻击，等等。

也有的专家预言 AI4DB 可能发展成为联机机器学习处理 (online machine learning processing, OLMP) 应用，并且成为和联机事务处理与联机分析处理应用一样广泛而重要的数据库应用领域。

14.4 数据库发展展望

大数据时代数据库技术、更广义的数据管理和数据处理技术遇到了前所未有的挑战，也迎来了新的发展机遇。本节从多数据模型并存、新硬件驱动、云原生数据库、支持混合事务分析处理型应用和面向人工智能的数据管理技术 5 个方面简要展望大数据时代数据库的发展趋势。

14.4.1 多数据模型并存

进入大数据时代，大数据应用的鲜明特征之一就是数据的多样性，既有结构化的关系数据、图数据、轨迹数据，也有非结构化的文本数据、图片数据，甚至是视频数据等。数据库管理系统的概念和技术正在扩展，形成大数据管理系统。该系统的一个基本要求是能够支持结构化、半结构化、非结构化等多种数据类型的组织、存储和管理，形成以量质相融合的知识管理中心，并以此提供面向知识服务的快速应用开发接口。

纵观现有的大数据管理系统，特别是以 NoSQL 数据库为主的大数据管理系统，走的是一种数据模型解决一类数据的道路。虽然也符合“One Size Fits a Bunch”的设计理念，但应用的要求仍然希望这里的“Bunch”尽可能地接近“All”。具体来说，图数据库支撑的是类似于社交网络、知识图谱、语义网等强关联数据的管理；关系数据库支撑的是人、财、物等需要精细数据管理的应用；键值对数据库适合非结构化或宽表这类无须定义的数据模式或模式高度变化的数据管理。在新型大数据应用背景下，把多种类型的数据用同一个大数据管理系统组织、存储和管理起来，并提供统一的访问接口，这似乎是大数据管理系统的一条必经之路。多数据模型并存下的数据管理存在很多技术挑战，具体包括以下几个方面：

① 数据如何建模？关系数据库具有严格的关系数据理论，并从降低数据冗余度和数据异常两个维度辅助数据建模。而新的数据模型下，甚至是多数据模型下，如何进行数据建模是一个值得探索的课题。

② 数据的访问提供统一的用户接口。多模型数据之间如何交互协同以及提供与存储层和计算层的统一交互接口。

③ 对多数据模型混合的数据处理提供执行优化，通过统一的资源管理优化任务调度，通过性能预估优化计算和通信等。

14.4.2 新硬件驱动

在处理器方面,多核、众核等技术的发展和普及,给事务处理技术带来了重大的机遇和挑战。CPU核数的增加,可以使数据库具备更强的对外数据服务能力,即允许对应用提供更大的连接数。这个结论对于查询引擎和存储系统可能是正确的,但对于事务处理却不一定正确。随着千核CPU的出现,数千个CPU核可以并发执行事务,这直接导致了并发事务数量的增加,使系统需要对大量事务进行并发控制。随着并发事务间的冲突操作量增大,对其协调开销也会增加(可能会造成巨大的死锁检测和事务回滚开销),并发控制变得尤为困难,并且CPU核数的增多也会削弱事务吞吐量的提升。最新研究表明,现有的并发控制算法均不能充分发挥CPU核数增多带来的性能优势。数据库系统需要对CPU这类硬件进行针对性的系统设计与优化。

高速网络(例如无限带宽 InfiniBand)以及可基于高速网络的远程直接存储器访问技术(remote direct memory access, RDMA)的出现,给分布式数据库系统架构的设计优化带来了机遇。利用RDMA技术,源节点可以直接访问目标主机内存中的数据,而不需要经过昂贵的TCP/IP协议中相邻层之间的数据复制和校验开销,也不需要目标主机CPU参与计算。此外,新型 InfiniBand 网络的延时和带宽已接近内存。因此,利用高速网络和RDMA技术,传统 share-nothing 架构的分布式数据库可以转为 share-memory 架构的分布式数据库和存算分离架构的云数据库。目前的研究表明,在快照隔离级别下分布式事务处理技术可以实现线性可扩展,但可串行化级别下尚未有研究表明分布式事务处理技术可以实现线性可扩展。目前,在数据中心内部,基于RDMA技术的分布式数据库系统已经在探索,但跨数据中心基于RDMA技术的分布式数据库系统研究仍是空白。

14.4.3 云原生数据库

数据库云服务主要是将传统数据库部署到云基础设施(虚拟机)上,数据库的部署、运维等由云服务提供商完成,用户可以更多地关注数据库逻辑结构设计、物理结构设计以及应用开发。这是云数据库发展的第一阶段。云数据库发展的第二阶段就是云原生数据库,这也是云数据库目前的发展方向。不像数据库云服务只是将传统数据库部署在云计算平台上作为一种服务,云原生数据库的目标是充分利用云计算中资源池化的能力,根据应用的特点,弹性伸缩数据库系统管理的能力。因此,云原生数据库首先要对系统进行解耦,这一点类似于 NewSQL 数据库。通过将系统解耦,当出现计算密集型应用时(例如“双十一”“春运”中出现的爆发式并发访问),可以通过云计算的资源池化能力扩展查询引擎以及事务管理子系统节点数量,以快速提升数据库系统的对外服务能力;当出现数据密集型应用时(需要管理流数据等应用),可以通过云计算的资源池化能力扩展存储节点数量,以快速提升数据库系统的存储能力。需要注意的是,由于存储价格和计算价格的不对称(通常存储价格要低得多),通过扩展存储节点数量来提升云数据库的存储能力,其成本要低得多。

14.4.4 支持混合事务分析处理型应用

在同一个系统中,基于同一套 SQL 标准,在同一份数据上同时支持事务型应用和分析型应用,是目前学术界和工业界研究的热点之一,也是数据库系统重要的发展方向之一。以往,如果要对事务型(OLTP)数据库中的数据进行复杂分析(分析型应用),一般的处理方法是:利用 ECTL 技术定期地把数据从 OLTP 数据库中导出到数据仓库中,之后再进行分析。这种做法的缺点在于导出数据需要占用大量的时间,而且在这个过程中可能有大量新数据产生或大量数据已被更新而成为旧数据,降低了数据分析的实时性。随着越来越多的数据分析应用对数据实时性的要求越来越高,事务型处理和分析型处理之间的界限开始逐渐变得模糊,混合事务分析处理系统应运而生。此类系统设计的难点在于:在同一个系统中,如何让分析型应用(通常是面向一个长事务)不影响事务型应用,同时还要保证分析型应用读取的数据是最新的和正确的。目前,学术界和工业界都在积极探索之中,有的面向 NewSQL 数据库,有的基于云原生数据库,有的则基于传统的集中式数据库。

14.4.5 面向人工智能的数据管理技术

面向人工智能的数据管理技术(简称 DB4AI 技术)在近些年也得到了广泛的关注。一方面,现有的人工智能技术面临使用门槛高、算法训练效率低、强依赖高质量数据等挑战。另一方面,数据库管理系统经过 60 余年的发展,积累了很多成熟的数据查询和数据管理技术,通过借鉴这些数据管理技术可以有效地解决上面的难题。

当前面向人工智能的数据管理技术研究主要有:面向人工智能的声明性语言、人工智能算法优化引擎、人工智能异构执行引擎和面向人工智能的数据治理引擎等。声明式语言(类 SQL)可以降低人工智能使用门槛;数据库优化技术(如索引技术、查询计划选择、视图缓存等)可以提升训练速度,提高资源利用率;数据治理技术可以提升数据质量,提升人工智能训练质量。

本章小结

从数据库发展的历程中,我们可以感悟到以下几点:

① **应用驱动技术创新**,应用需求是数据库产生和不断发展的原动力。要从不断涌现的应用需求中提炼和发展数据管理新技术、新理论,为用户提供更强大、更方便的服务。简言之,数据库技术从应用中来,到应用中去。

② **数据建模**是数据库对数据进行抽象的有力武器,数据模型是数据库发展的主线。

③ **数据库系统的三级模式的分层架构**使数据库系统具有稳定性和独立性,这是研制和开发大型软件系统的优良结构。

④ 数据库管理系统的数据存取、事务管理、查询优化到语言处理等各个模块结构科学合

理,积累了许多宝贵的技术和方法。应用的多样性驱动数据库技术与新硬件、云计算、人工智能、区块链等新技术的有机融合,有效解决数据库系统弹性扩容、高可用、高性能等问题。其中每个模块各自独立发展,模块与模块之间通过解耦与重构成为当今大数据管理系统的重要构件。

习 题 14

1. 请描述数据库发展每一阶段的代表性事件、代表人物和典型系统。
2. 科学给我们知识,历史给我们智慧^①。你通过学习数据库技术获得了哪些(对你个人而言)最重要、最有用的知识?通过学习数据库发展历史有哪些感悟和体会,获得了哪些智慧?
3. 什么是 SQL、NoSQL 与 NewSQL? 这三者之间有什么联系和区别?
4. 什么是混合事务分析处理,它与传统的面向事务型的应用系统和面向分析型的应用系统有什么区别?
5. 什么是云数据库?云数据库发展的两个阶段有什么区别?
6. 请谈一谈新一代分布式数据库与传统分布式数据库的联系与区别。
7. 请谈一谈新硬件对数据库技术发展的作用,可以举 1~2 个例子进行说明。

参考文献 14

- [1] 杜小勇,卢卫,张峰. 大数据管理系统的历史、现状与未来[J]. 软件学报, 2019, 30(01): 127-141.
 - [2] 崔斌,高军,童咏昕,等. 新型数据管理系统研究进展与趋势[J]. 软件学报, 2019, 30(01): 164-193.
 - [3] ABADI D, AILAMAKI A, ANDERSEN D G, et al. The seattle report on database research[J]. SIGMOD Record, 2019, 48(4): 44-53.
 - [4] 萨师煊,王珊. 数据库系统概论[M]. 3版. 北京:高等教育出版社,2000.
- 为了反映数据库技术的发展,《数据库系统概论》第3版增加了新技术篇,包括第12章数据库技术新发展、第13章面向对象数据库系统、第14章分布式数据库系统和第15章并行数据库系统。
- [5] 萨师煊,王珊. 数据库系统概论[M]. 4版. 北京:高等教育出版社,2006.
- 《数据库系统概论》第4版更新了新技术篇的内容和章节,包括第13章数据库技术新发展、第14章分布式数据库系统、第15章对象关系数据库系统、第16章XML数据库和第17章数据仓库与联机分析处理技术。
- [6] 萨师煊,王珊. 数据库系统概论[M]. 5版. 北京:高等教育出版社,2014.
- 《数据库系统概论》第5版更新了新技术篇的内容和章节,包括第13章数据库技术发展概述、第14章大数据管理、第15章内存数据库系统和第16章数据仓库与联机分析处理技术。
- [7] BINNIG C, CROTTY A, GALAKATOS A, et al. The end of slow networks: it's time for a redesign [C]. Proceedings of the VLDB Endowment. 2016, 9(7): 528-539.

^① 化学家傅鹰的名言。

- [8] CORBETT J C, DEAN J, EPSTEIN M, et al. Spanner: Google's globally distributed database[J]. ACM Transactions on Computer Systems, 2013, 31(3): 1-22.
- [9] TAFT R, SHARIF I, MATEI A, et al. CockroachDB: the resilient geo-distributed SQL database[C]. Proceedings of the 2020 ACM SIGMOD International Conference on Management of Data, 2020: 1493-1509.
- [10] HUANG D X, LIU Q, CUI Q, et al. TiDB: a raft-based HTAP database[C]. Proceedings of VLDB Endowment. 2020, 13(12): 3072-3084.
- [11] 柴茗珂, 范举, 杜小勇. 学习式数据库系统: 挑战与机遇[J]. 软件学报, 2020, 31(03): 806-830.
- [12] LIU T Y, FAN J, LUO Y Q, et al. Adaptive data augmentation for supervised learning over missing data[J]. Proceedings of the VLDB Endowment, 2021, 14(7): 1202-1214.

伴随着数字经济的兴起,数据已经渗透到每一个行业和业务领域,成为重要的生产要素。企业与政府机构的数字化转型是时代发展的趋势,大数据已成为当今科技界、企业界和各国政府关注的热点^{[1,2][11~16]}。以人工智能技术为代表,人们对于大数据的挖掘和运用,预示着新一波生产力增长和科技发展浪潮的到来。

科技界和工业界在研究大数据理论和技术、开发大数据系统,企业、政府、各行各业都在努力应用大数据。大数据正在孕育新的学科——数据科学。大数据正在创造价值,形成新的产业,展现出无穷的变化和广阔的前景。

本章介绍什么是大数据、大数据的特征以及大数据管理系统,着重从数据管理的角度来讨论这些系统和技术。近年来,由于大数据管理的相关理论、技术和系统都在快速地进步和发展,本章介绍的内容也将随着时间的推移不断更新。

15.1 大数据概述

15.1.1 什么是大数据

什么是大数据?大数据和数据库领域的超大规模数据库(VLDB)、海量数据(massive data)有什么不同呢?

“超大规模数据库”这个词是 20 世纪 70 年代中期出现的,在数据库领域一直享有盛誉的 VLDB 国际会议就是 1975 年开始举办的,当时数据库中管理的数据集有数百万条记录就是超大规模了。“海量数据”则是 21 世纪初出现的新词,用来描述更大的数据集以及更加丰富的数据类型。2008 年 9 月《自然》杂志出版专刊 *Big Data: Science in the Petabyte Era*,“大数据”这个词开始被广泛传播。上述这些词都表示需要管理的数据规模很大,相对于当时的计算机存储和处理技术水平而言遇到了技术挑战,需要研究和发展更加先进的技术才能有效地存储、管理和处理它们。

面对“超大规模”数据,人们研究了数据库管理系统的高效实现技术,包括系统的三级模