

伴随着数字经济的兴起,数据已经渗透到每一个行业和业务领域,成为重要的生产要素。企业与政府机构的数字化转型是时代发展的趋势,大数据已成为当今科技界、企业界和各国政府关注的热点^{[1,2][11~16]}。以人工智能技术为代表,人们对于大数据的挖掘和运用,预示着新一波生产力增长和科技发展浪潮的到来。

科技界和工业界在研究大数据理论和技术、开发大数据系统,企业、政府、各行各业都在努力应用大数据。大数据正在孕育新的学科——数据科学。大数据正在创造价值,形成新的产业,展现出无穷的变化和广阔的前景。

本章介绍什么是大数据、大数据的特征以及大数据管理系统,着重从数据管理的角度来讨论这些系统和技术。近年来,由于大数据管理的相关理论、技术和系统都在快速地进步和发展,本章介绍的内容也将随着时间的推移不断更新。

15.1 大数据概述

15.1.1 什么是大数据

什么是大数据?大数据和数据库领域的超大规模数据库(VLDB)、海量数据(massive data)有什么不同呢?

“超大规模数据库”这个词是 20 世纪 70 年代中期出现的,在数据库领域一直享有盛誉的 VLDB 国际会议就是 1975 年开始举办的,当时数据库中管理的数据集有数百万条记录就是超大规模了。“海量数据”则是 21 世纪初出现的新词,用来描述更大的数据集以及更加丰富的数据类型。2008 年 9 月《自然》杂志出版专刊 *Big Data: Science in the Petabyte Era*,“大数据”这个词开始被广泛传播。上述这些词都表示需要管理的数据规模很大,相对于当时的计算机存储和处理技术水平而言遇到了技术挑战,需要研究和发展更加先进的技术才能有效地存储、管理和处理它们。

面对“超大规模”数据,人们研究了数据库管理系统的高效实现技术,包括系统的三级模

式体系架构,数据与应用分离(即数据独立性)的思想(增加了数据库管理系统的适应性和应用的稳定性),关系数据库的结构化查询语言 SQL、查询优化技术、事务处理(主要包括并发控制与故障恢复)技术等;创建了关系数据理论,奠定了关系数据库坚实的理论基础。同时,数据库技术在商业上也取得了巨大成功,引领了上百亿美元的产业,有力地促进了以联机事务处理和联机分析处理为标志的商务管理与商务智能应用的发展。这些技术精华和成功经验为今天大数据管理和分析奠定了基础。

为了应对“海量数据”的挑战,人们研究了各种半结构化数据和非结构化数据的数据模型,以及对它们的有效管理、多源数据的集成问题等。因此,大数据并不是当前时代所独有的特征,而是伴随着社会发展和科技水平的提高而不断发展演化的。

当前,人们从不同的角度在诠释大数据的内涵。关于大数据的一个定义是:一般意义上,大数据是指无法在可容忍的时间内,用现有的信息技术和硬件工具对其进行感知、获取、管理、处理和服务的数据集合。

还有一些专家给出的定义是^[3]:大数据通常被认为是 PB(1 024 TB)或 EB(1 EB=1 024×1 024 TB)或更高数量级的数据,包括结构化的、半结构化的和非结构化的数据。其规模或复杂程度超出了传统数据库和软件技术所能管理和处理的数据集范围。

也有一些专家按大数据的应用类型,将大数据分为海量事务处理数据(企业联机事务处理应用)、海量交互数据(社交网络、传感器、GPS、Web 信息)和海量分析处理数据(企业联机分析处理应用)。

海量事务处理数据的应用特点是:数据海量,读写操作比较简单;访问和更新频繁,一次处理的数据量不大,但要求支持事务的 ACID 特性;对数据的完整性和安全性要求高,必须保证强一致性。

海量交互数据的应用特点是:实时交互性强,但不要求支持事务特性;数据的典型特点是类型多样异构、不完备、噪声大、数据增长快,不要求具有强一致性。

海量分析处理数据的应用特点是:面向海量数据分析,计算复杂,往往涉及多次迭代才能完成;追求数据分析的高效率,但不要求支持事务特性;一般采用并行与分布式处理框架实现。数据的特点是同构性(如关系数据、文本数据或列模式数据)和较好的稳定性(不存在频繁的更新操作)。

15.1.2 大数据的特征

大数据不仅仅是量“大”,它具有许多重要的特征,人们将其归纳为若干个 V,即 volume、variety、velocity、value。大数据的这些特征给我们带来了巨大的挑战^[4]。

1. 数据量(volume)大

大数据的首要特征是数据量巨大,而且是持续、急剧地膨胀。很多研究机构估算,2020 年全球数据总量已经超过了 40 ZB。

大规模数据的几个主要来源包括:

① 科学研究(天文学、生物学、高能物理等)、计算机仿真领域。例如,大型强子对撞机每年积累的新数据量为 15 PB 左右。

② 互联网应用、电子商务领域、自媒体网站。根据 2020 年微博用户发展报告,新浪微博的最高日活跃用户数达到 2.24 亿,这些用户每天产生的自媒体信息总量达到 10 TB 规模。又如,沃尔玛(Walmart)公司每天通过数千商店向全球客户销售数亿件商品,为了对这些数据进行分析,沃尔玛公司数据仓库系统的数据规模达到 4 PB,并且在不断扩大。

③ 传感器数据(sensor data)。分布在不同地理位置上的传感器对所处环境进行感知,不断生成数据。即便对这些数据进行过滤,仅保留部分有效数据,长时间累积的数据量也是惊人的。

④ 网站点击流数据(click stream data)。为了进行有效的市场营销和推广,用户在网上的每次点击及其时间都被商家记录下来。利用这些数据,服务提供商可以对用户行为模式进行深入的分析,从而提供更加具有针对性的个性化服务。

⑤ 移动设备数据(mobile device data)。通过移动电子设备,包括移动电话和掌上电脑(PDA)、导航设备等,可以获得设备和人员的位置、移动轨迹、用户行为等信息。对这些信息及时分析可以帮助我们进行有效的决策,比如交通监控和疏导。

⑥ 射频识别数据(RFID data)。射频识别技术可以嵌入产品,实现物体的跟踪,在其广泛应用的过程中会产生大量的数据。

⑦ 传统的数据库和数据仓库所管理的结构化数据。这一类数据的数据量也在急速增长。

总之,无论是科学研究还是商业应用,无论是企业部门还是个人,时时处处都在产生数据。几十年来,管理大规模且迅速增长的数据一直是极具挑战性的问题。目前数据增长的速度已经超过了计算资源增长的速度,这就需要设计新的计算机软硬件,设计新硬件下的存储子系统。而存储子系统的改变将影响数据管理和数据处理的各个方面,包括数据分布、数据复制、负载均衡、查询算法、查询调度、一致性控制、并发控制和恢复方法等。

2. 类型多样性(variety)

数据的多样性是指数据类型多样,因此数据表示和语义解释也多种多样。现在,越来越多的应用使用和产生的数据类型不再是纯粹的关系数据,更多的是非结构化、半结构化的数据,如文本、网络(图)、图形、图像、音频、视频、网页、推特(tweet)和博客(blog)等。现代互联网应用呈现出非结构化数据大幅增长的特点。

对异构海量数据的组织、建模、分析、检索和管理是基础性的挑战。例如,图像和视频数据虽具有存储和播放结构,但这种结构不适合进行上下文语义分析和搜索。对非结构化数据的分析在许多应用中成为一个显著的瓶颈。传统的数据分析算法在处理结构化数据时,功能和效率方面都比较成熟,是否可以将各种类型的数据内容转化为有结构的格式以进一步采用结构化的方式分析呢?此外,考虑到当今大多数数据是直接以数字格式生成的,是否可以干预数据的产生过程,以便日后的数据分析?在数据分析之前还要对数据进行清洗和纠错,对缺失和错误数据进行处理等。因此,针对半结构化、非结构化数据的表示、存取和分析技术需要大量的基

基础研究。

3. 变化快(velocity)

大数据的第三个特点是数据变化快,一方面指数据到达的速度很快,另一方面指有些场景需要数据进行处理的时间很短,或者要求响应速度很快,即实时响应。例如,Facebook 数据产生速度非常快,每天增加的数据超过 500 TB,可分享的条目达 25 亿条。“双十一”“618”等购物节是中国特有的现象级应用,其中“双十一”的订单数量和交易金额逐年上升,2020 年“双十一”的订单量创建峰值达到 58.3 万笔每秒,总交易金额达到 4 982 亿元。

许多大数据往往以数据流的形式动态、快速地产生和演变,具有很强的时效性。流数据来得快,对流数据的采集、过滤、存储和利用,需要充分考虑和掌控其快变性;加上要处理的数据集很大,数据分析和处理的时间也将很长。而在实际应用需求中,常常要求立即得到分析结果。例如,在进行信用卡交易时,如果怀疑该信用卡涉嫌欺诈,则应在交易完成之前做出判断,以防止非法交易的产生。这就要求系统具有极强的处理能力和有效的处理策略,可以事先对历史交易数据进行分析 and 预计算,再结合新数据进行少量的增量计算便可迅速做出判断。对于大数据上的实时分析处理,需要借鉴传统数据库中非常成功的查询优化技术,包括针对不同应用和不同数据内容的索引技术。

4. 蕴含价值(value)

大数据的价值是潜在的、巨大的。大数据不仅具有经济价值和产业价值,而且具有科学价值。这是大数据最重要的特点,也是大数据的魅力所在。

2012 年 3 月美国政府即启动“大数据研究和发展计划”,这是继 1993 年美国宣布“信息高速公路”计划后的又一次重大科技发展部署。2012 年 5 月英国政府注资建立了世界上第一个大数据研究所。同年,日本也出台计划重点关注大数据领域的研究。在我国,2012 年 10 月中国计算机学会成立了 CCF 大数据专家委员会,科学技术部 2013 年启动了 973、863 大数据研究项目,以及后来的“云计算与大数据”重点研发专项。2015 年国务院发布《促进大数据发展行动纲要》,首次提出“国家大数据战略”,旨在全面推进我国大数据发展和应用,加快建设数据强国,将大数据战略上升为国家战略。2017 年开始实施《大数据产业发展规划(2016—2020 年)》。2021 年工业和信息化部发布《“十四五”大数据产业发展规划》,描绘了“十四五”期间大数据产业发展的具体蓝图。从某种意义上,一个国家拥有数据的规模和运用数据的能力已成为综合国力的重要组成部分,对数据的占有和控制也成为国与国之间、企业与企业之间新的争夺焦点。

大数据价值的潜在性是指数据蕴含的巨大价值只有通过大数据以及数据之间蕴含的联系进行复杂的分析、反复深入的挖掘才能获得。而大数据自身存在的规模巨大、异构多样、快变复杂、安全隐私等问题,以及数据孤岛、信息私有、缺乏共享的客观现实都阻碍了数据价值的创造。其巨大潜力和目标实现之间还存在着巨大的鸿沟。

近年来,大数据的经济价值和产业价值已经明显地显现出来。一些掌握大数据的互联网公

司基于数据采集、数据分析和数据挖掘等技术,帮助企业为客户提供更优良的个性化服务,降低营销成本,提高生产效率,增加利润。大数据分析帮助企业优化管理,调整内部机构,提高服务质量。大数据是未来产业竞争的核心支撑。大数据价值的实现需要通过数据共享、交叉复用才能获得。因此,随着数据成为生产要素,大数据也将会如基础设施一样,有数据提供方、使用方、管理者和监管者等,成为一个大产业。

我国研究者 2012 年就已提出要把数据本身作为研究对象,关注数据科学的研究,研究大数据的科学共性问题^[5]。数据科学是以大数据为研究对象,横跨信息科学、社会科学、网络科学、系统科学、心理学、经济学等诸多领域的新兴交叉学科。其学科交叉的特点非常鲜明。

大数据可以用于科学研究。2007 年 1 月,James Gray 在加州山景城召开的 NRC-CSTB 上的演讲中提出将人类科学研究分为 4 类范式:以记录和描述自然现象为主的实验科学(第一范式),以模型和归纳为特征的理论科学(第二范式),以模拟仿真为特征的计算机科学(第三范式),以及从计算机科学中把数据密集型科学区分出来的数据密集型科学发现(第四范式)。James Gray 认为,对于科学研究,科研人员只需从大量数据中查找和挖掘所需要的信息和知识,无须直接面对所研究的物理对象。例如,在天文学领域,天文学家的工作方式发生了大幅度转变。以前,天文学家的主要工作是进行太空拍照。如今,所有照片都已存放在数据库中,天文学家的任务变为从数据库的海量数据中发现有趣的物体或现象。科学研究的第四范式将不仅是研究方式的转变,也是人们思维方式的大变化^[3]。

关于大数据的特征,IBM 还提出了另一个 V,即 veracity,称为真实性,旨在针对大数据包含的噪声、数据缺失、数据不确定等问题强调数据质量的重要性,以及保证数据质量所面临的巨大挑战。

15.2 大数据管理系统

大数据的价值要得到发挥,首要条件是能够被有效管理起来,也就是要解决多类型数据的存取问题:将业务系统产生的具有 4V 特性的大数据及时地存储到系统中,以及高效读取到具有访问权限的业务系统所需要的数据,这就是大数据管理系统的任务。

大数据概念被广泛认可之前,在数据管理的层面上,人们主要关注关系数据库系统,也是本书之前章节主要介绍的内容。也曾有一些观点认为,传统关系数据库能够解决大部分数据管理问题,但这种观点在面临大数据时代的数据管理任务时就已不再成立了。

数据模型是数据管理系统的基础,它与被管理的数据类型密切相关。大数据的多样性带来了不同类型的数据,不同类型的数据有不同的访问接口,导致了不同的数据模型需求。为此,在大数据背景下,人们针对不同类型的数据设计并开发了不同类型的大数据管理系统。如前所述,这些扩展出来的数据类型已经超出了传统数据库所擅长管理的模型数据。本章结合几类最为常见的数据类型:键值对数据、文档数据、图数据及时序数据,分别介绍它们对应的