

第 16 章 数据仓库与联机分析处理

数据库系统中存在着两类不同的数据处理工作：操作型处理和分析型处理，也称作联机事务处理(OLTP)和联机分析处理(OLAP)。本章首先介绍传统数据仓库与联机分析处理技术，在此基础上介绍大数据时代新型数据仓库与混合事务分析处理(HTAP)技术。

操作型处理也叫事务处理，是指对数据库联机的日常操作，通常是对一个或一组记录的查询和修改，如火车售票系统、银行通存通兑系统、税务征收管理系统等。这些系统要求快速响应用户请求，对数据的安全性、完整性以及事务吞吐量要求很高。

分析型处理是指对数据的查询和分析操作，通常是对海量的历史数据进行查询和分析，如金融风险预测预警系统、证券股市违规分析系统等。这些系统要访问的数据量非常大，查询和分析的操作十分复杂。

OLTP 和 OLAP 两者之间的差异，使得传统的数据库技术不能同时满足两类数据的处理要求。因此，20 世纪 80 年代数据仓库(DW)技术就应运而生了。数据仓库的建立将操作型处理和分析型处理区分开来。传统的数据库系统为操作型处理服务，数据仓库为分析型处理服务，二者各司其职，泾渭分明。越来越多的企业认识到数据仓库能够带来效益，逐步在原有数据库基础之上建立起了自己的数据仓库系统^[1]。

16.1 数据仓库技术

数据仓库和数据库只有一字之差，似乎是一样的概念，但实际则不然。数据仓库是为了构建新的分析处理环境而出现的一种数据存储和组织技术。由于分析处理和事务处理具有极不相同的性质，因而两者对数据也有着不同的要求。W. H. Inmon 在其所著的 *Building the Data Warehouse*^[2]一书中列出了操作型数据与分析型数据之间的区别，具体如表 16.1 所示。

基于操作型数据和分析型数据之间的区别，Inmon 给出了数据仓库的定义：数据仓库是一个用以更好地支持企业(或组织)决策分析处理的面向主题的、集成的、不可更新的、随时间不断变化的数据集合。数据仓库本质上和数据库一样，是长期储存在计算机内的有组织、可共享的数据集合。

表 16.1 操作型数据与分析型数据的区别

操作型数据	分析型数据
细节的	综合的或提炼的
在存取瞬间是准确的	代表过去的数据
可更新	不可更新
操作需求事先可知道	操作需求事先不知道
生命周期符合系统开发生命周期 (system development life cycle, SDLC)	完全不同的生命周期
对 ACID 特性中的数据一致性要求高	对数据一致性要求宽松
一个时刻操作一个元组	一个时刻操作一个集合
事务驱动	分析驱动
面向事务处理, 要求响应速度快	面向分析处理
一次操作数据量小	一次操作数据量大
支持日常操作	支持管理决策需求

1. 数据仓库的基本特征

数据仓库中的数据具有以下 4 个基本特征, 这也是数据仓库和数据库主要的区别。

(1) 主题与面向主题

数据仓库中的数据是面向主题进行组织的。主题是一个抽象的概念, 是在较高层次上对企业信息系统中的数据综合、归类并进行分析利用的抽象; 在逻辑意义上, 它对应企业中某一宏观分析领域所涉及的分析对象。例如对一家商场而言, 概括分析领域的对象, 应有的主题包括供应商、商品、顾客等。面向主题的数据组织方式是根据分析要求将数据组织成一个完备的分析领域, 即主题域。

主题是一个在较高层次上对数据的抽象, 这使得面向主题的数据组织可以独立于数据的处理逻辑, 因而可以在这种数据环境上方便地开发新的分析型应用。同时, 这种独立性也是建设企业全局数据库所要求的, 所以面向主题不仅适用于分析型数据环境的数据组织方式, 同时也适用于建设企业全局数据库的组织。

(2) 数据仓库是集成的

前面已经讲到, 操作型数据与分析型数据之间差别甚大, 数据仓库的数据是从原有的分散的数据库数据中抽取来的, 因此数据在进入数据仓库之前必然要经过加工与集成, 统一与综合。这一步实际上是数据仓库建设中最关键、最复杂的一步。

首先要统一原始数据中所有矛盾之处, 如字段的同名异义、异名同义, 单位不统一, 字长不一致等。然后将原始数据结构做一个从面向应用到面向主题的大转变, 还要进行数据综合和计算。数据仓库中的数据综合工作可以在抽取数据时完成, 也可以在进入数据仓库以后进行综

合时完成。

(3) 数据仓库是不可更新的

数据仓库主要供决策分析之用，所涉及的数据操作主要是数据查询，一般情况下并不进行修改操作。数据仓库存储的是相当长一段时间内的历史数据，是不同时点数据库快照的集合，以及基于这些快照进行统计、综合和重组的导出数据，不是联机处理的数据。联机事务处理数据库中的数据经过 ECTL 过程存储在数据仓库中，一旦数据存放到数据仓库中数据就不可再更新了。

(4) 数据仓库是随时间变化的

数据仓库中的数据不可更新，是指数据仓库的用户进行分析处理时是不进行数据更新操作的，但并不是说在数据仓库的整个生存周期中数据集是不变的。

数据仓库的数据是随时间的变化不断变化的，这一特征表现在以下三个方面：

① 数据仓库随时间变化不断增加新的数据内容。

② 数据仓库随时间变化不断删去旧的数据内容。

③ 数据仓库中包含大量的综合数据，这些综合数据中很多与时间有关。例如数据按照某一时间段进行综合，或隔一定的时间片进行采样等，这些数据就会随时间的变化不断地进行重新综合。因此，数据仓库中数据的标识码都包含时间项，以标明数据的历史时期。

2. 数据仓库中的数据组织

数据仓库中的数据分为多个级别：早期细节级、当前细节级、轻度综合级和高度综合级，其数据组织结构如图 16.1 所示。元数据经过 ECTL 过程进入数据仓库，首先进入当前细节级，根据具体的分析处理需求再进行综合，进而成为轻度综合级和高度综合级。随着时间的推移，早期的数据将转入早期细节级。




图 16.1 数据仓库的数据组织结构

由于数据仓库的主要应用是分析处理，绝大部分查询都针对综合数据，因而多重级别的数据组织可以大大提高联机分析的效率。不同级别的数据可以存储在不同的存储设备上。例如，可以将综合级别高的数据存储快速设备甚至放在内存中，这样对于绝大多数查询分析而言其系统性能将大大提高；而综合级别低的数据则可存储在磁盘阵列、光盘组或磁带上。

3. 数据仓库系统的体系结构

数据仓库系统的体系结构如图 16.2 所示, 主要由数据仓库的后台工具、数据仓库 (DW) 与数据仓库服务器、联机分析处理 (OLAP) 服务器和前台工具组成。




图 16.2 数据仓库系统的体系结构

数据仓库的后台工具包括数据抽取、清洗、转换、装载和维护 (maintenance) 等工具, 简称 ECTL/ETL 工具。

数据仓库服务器相当于数据库管理系统, 它负责数据仓库中数据的存储管理和数据存取, 并给联机分析处理服务器和前台工具提供存取接口 (如 SQL 查询接口)。数据仓库服务器目前一般是关系数据库管理系统或扩展的关系数据库管理系统, 即由传统数据库厂商对数据库管理系统加以扩展修改, 使它能更好地支持数据仓库的功能。

联机分析处理服务器为前台工具和用户提供多维数据视图。用户不必关心它的分析数据 (即多维数据) 到底存储在什么地方以及是怎么存储的。

前台工具包括查询报表工具、多维分析工具、数据挖掘工具和分析结果可视化工具等。

16.2 联机分析处理技术

联机分析处理是以海量数据为基础的复杂分析技术。联机分析处理支持各级管理决策人员从不同的角度, 快速灵活地对数据仓库中的数据进行复杂查询和多维分析处理, 辅助各级管理人员进行正确决策, 提高企业的竞争力。

1. 多维数据模型

多维数据模型是数据分析时用户的数据视图, 是面向分析的数据模型, 用于为分析人员提供多种观察的视角和面向分析的操作。