

3. 数据仓库系统的体系结构

数据仓库系统的体系结构如图 16.2 所示, 主要由数据仓库的后台工具、数据仓库 (DW) 与数据仓库服务器、联机分析处理 (OLAP) 服务器和前台工具组成。




图 16.2 数据仓库系统的体系结构

数据仓库的后台工具包括数据抽取、清洗、转换、装载和维护 (maintenance) 等工具, 简称 ECTL/ETL 工具。

数据仓库服务器相当于数据库管理系统, 它负责数据仓库中数据的存储管理和数据存取, 并给联机分析处理服务器和前台工具提供存取接口 (如 SQL 查询接口)。数据仓库服务器目前一般是关系数据库管理系统或扩展的关系数据库管理系统, 即由传统数据库厂商对数据库管理系统加以扩展修改, 使它能更好地支持数据仓库的功能。

联机分析处理服务器为前台工具和用户提供多维数据视图。用户不必关心它的分析数据 (即多维数据) 到底存储在什么地方以及是怎么存储的。

前台工具包括查询报表工具、多维分析工具、数据挖掘工具和分析结果可视化工具等。

16.2 联机分析处理技术

联机分析处理是以海量数据为基础的复杂分析技术。联机分析处理支持各级管理决策人员从不同的角度, 快速灵活地对数据仓库中的数据进行复杂查询和多维分析处理, 辅助各级管理人员进行正确决策, 提高企业的竞争力。

1. 多维数据模型

多维数据模型是数据分析时用户的数据视图, 是面向分析的数据模型, 用于为分析人员提供多种观察的视角和面向分析的操作。

多维数据模型的数据结构可以用一个多维数组来表示,即(维1,维2,...,维 n ,度量值)。例如,图16.3所示的电器商品销售数据是按时间、地区、电器商品种类,加上度量“销售额”组成的一个三维数组(时间,地区,电器商品种类,销售额)。三维数组可以用一个立方体来直观地表示。一般地,多维数组用多维方体(cube)来表示,也称为超立方体。




图 16.3 多维数据模型示例 (电器商品销售数据)

2. 多维分析操作

常用的联机分析处理多维分析操作有切片 (slice)、切块 (dice)、旋转 (pivot)、向上综合 (roll-up)、向下钻取 (drill-down) 等。通过这些操作,用户能从多角度和多侧面观察数据、剖析数据,从而深入了解包含在数据中的信息与内涵。

3. 联机分析处理的实现方式

联机分析处理服务器透明地为分析软件 and 用户提供多维数据视图,实现对多维数据的存储、索引、查询和优化等功能。联机分析处理服务器一般按照多维数据模型的不同实现方式,分为 MOLAP 结构、ROLAP 结构、HOLAP 结构等多种结构。

MOLAP 结构直接以多维方体来组织数据,以多维数组来存储数据,支持直接对多维数据的各种操作。人们也常常称这种按照多维方体来组织和存储的数据结构为多维数据库 (multi-dimensional database, MDDB)。

ROLAP 结构用关系数据库管理系统或扩展的关系数据库管理系统来管理多维数据,用关系表来组织和存储多维数据。同时,它将多维方体上的操作映射为标准的关系操作。

ROLAP 将多维方体结构划分为两类表,一类是事实表 (fact table),另一类是维表 (dimension table)。事实表用来描述和存储多维方体的度量值及各个维的码值,维表用来描述维信息。ROLAP 用关系数据库的二维表来表示事实表和维表,也就是说,ROLAP 用星型模式和雪花模式来表示多维数据模型。

星型模式 (star schema) 通常由一个中心表 (事实表) 和一组维表组成。如图 16.4 所示,该星型模式示例的中心是销售事实表,其周围的维表有时间维表、顾客维表、销售员维表、制造商维表和产品维表。事实表一般很大,维表一般较小。

将星型模式中的维表按层次进一步细化,就形成了雪花模式。例如,对于图 16.4 所示的星型模式,顾客维表可以按所在地区位置分类聚集;时间维表则可以有二类层次——日、月,

日、星期；制造商维表可以按工厂及工厂所在地区分层等。如图 16.5 所示，在星型维表的角上又出现了分支，这样变形的星型模式被称为雪花模式（snowflake schema）。



图 16.4 星型模式示例



图 16.5 雪花模式

HOLAP（hybrid OLAP）则是 MOLAP 和 ROLAP 的混合结构。

近年来，出现了越来越多的大规模实时分析应用，如实时库存/定价、移动应用推荐、欺诈检测、风险分析、物联网等。这些应用要求数据仓库管理系统不仅能够对最新的数据做出实时的分析，也要能够快速处理并发的任务，其中一些应用甚至要求将分析查询作为事务处理的一部分。这类既具有分析处理特点又具有事务处理特点的特殊类型数据处理应用，即第 14 章已提到的混合事务分析处理（HTAP）。

16.3 混合事务分析处理技术

随着大规模实时分析应用的需求增多，如何在大数据集上进行混合事务分析处理引起了学术界和工业界的共同兴趣。人们也把混合事务分析处理称为混合负载型数据库，其核心思想是通过一套数据库软件，通过同一个 SQL 接口在同一份数据上既支持事务交易负载，又支持分析负载。

人们从不同的角度提出了若干种混合事务分析处理解决方案，根据不同的应用可将其分为两大类：单引擎解决方案和多引擎解决方案。

1. 单引擎解决方案

传统的关系数据库管理系统（如 DB2、Oracle、SQL Server 等）采用同一个引擎来同时支持事务型和分析型应用负载。这类系统主要采取行存储的方式，其缺点是对分析型负载的查询处理效率比较低。

为了同时提高事务型和分析型应用负载的处理效率，研究人员探索了行列混合存储的方式。一些系统开始设计时采用的是适合分析处理的列存储格式，后来为了支持事务型处理增加