

日、星期；制造商维表可以按工厂及工厂所在地区分层等。如图 16.5 所示，在星型维表的角上又出现了分支，这样变形的星型模式被称为雪花模式（snowflake schema）。



图 16.4 星型模式示例



图 16.5 雪花模式

HOLAP（hybrid OLAP）则是 MOLAP 和 ROLAP 的混合结构。

近年来，出现了越来越多的大规模实时分析应用，如实时库存/定价、移动应用推荐、欺诈检测、风险分析、物联网等。这些应用要求数据仓库管理系统不仅能够对最新的数据做出实时的分析，也要能够快速处理并发的任务，其中一些应用甚至要求将分析查询作为事务处理的一部分。这类既具有分析处理特点又具有事务处理特点的特殊类型数据处理应用，即第 14 章已提到的混合事务分析处理（HTAP）。

16.3 混合事务分析处理技术

随着大规模实时分析应用的需求增多，如何在大数据集上进行混合事务分析处理引起了学术界和工业界的共同兴趣。人们也把混合事务分析处理称为混合负载型数据库，其核心思想是通过一套数据库软件，通过同一个 SQL 接口在同一份数据上既支持事务交易负载，又支持分析负载。

人们从不同的角度提出了若干种混合事务分析处理解决方案，根据不同的应用可将其分为两大类：单引擎解决方案和多引擎解决方案。

1. 单引擎解决方案

传统的关系数据库管理系统（如 DB2、Oracle、SQL Server 等）采用同一个引擎来同时支持事务型和分析型应用负载。这类系统主要采取行存储的方式，其缺点是对分析型负载的查询处理效率比较低。

为了同时提高事务型和分析型应用负载的处理效率，研究人员探索了行列混合存储的方式。一些系统开始设计时采用的是适合分析处理的列存储格式，后来为了支持事务型处理增加

了行存储格式。例如, SAP 公司的 HANA 系统或 Oracle 公司的 TimesTen 系统, 最初主要为了提高分析型工作负载的查询性能而针对内存列存储格式进行了优化, 后来为了支持 ACID 事务又增加了行存储, 当处理事务型查询时则采用行存储的方式进行数据访问。

也有一些系统一开始设计时采用的是适合事务处理的行存储格式, 后来为了支持分析型处理而增加了列存储格式。例如, MemSQL 系统最初专门针对可扩展的内存事务处理设计了存储引擎, 内存中以行格式存储数据, 后来又增加了对分析型处理的支持, 当数据写入磁盘时将其转换为列格式, 以便更快地进行分析。类似地, 为了支持混合事务分析处理负载, IBM dashDB 系统也由传统的行存储格式转向了行列混合存储格式。

另外, 也有一些研究人员从一开始就致力于构建一个可以根据负载类型对存储格式进行自适应调整的系统, 比如卡内基·梅隆大学新推出的 Peloton 系统即提供了自适应的行列混合存储格式, 能够根据所请求的负载类型在运行时动态改变数据的存储格式。

以上这些系统在进行事务处理和分析处理时, 都需要在行存储和列存储之间进行数据格式的转换。这些转换的存在会影响分析处理的实时性, 在进行分析处理时用到的数据有可能不是最新的。

2. 多引擎解决方案

多引擎解决方案通过将不同的系统耦合在一起, 来完成针对大数据环境下混合事务分析处理负载的支持功能。通常有两种方式: 联机事务处理+联机分析处理方式和联机事务处理+NoSQL 方式。

联机事务处理+联机分析处理方式将一个联机事务处理系统和一个联机分析处理系统松散地耦合在一起。应用程序负责维护混合架构。联机事务处理系统中的操作型数据通过标准的 ETL 工具抽取到联机分析处理系统。这种做法目前比较普遍。应用程序使用传统的联机事务处理数据库来处理事务性工作负载, 而分析型数据则被整理到基于 HDFS 的 Parquet 或 ORC 文件中, 用于进行分析查询。因此, 在联机分析处理系统中可以查询的数据和联机事务处理系统中可以看到的数 据之间存在延迟。

联机事务处理+NoSQL 方式将一个联机事务处理系统和一个 NoSQL 大数据分析系统松散地耦合在一起。例如在 SAP HANA Vora 系统中, 事务处理通过 HANA 执行, 而分析请求由 Spark SQL 处理。还有一些最近开发的数据库管理引擎也采取了类似的方式, 例如 SnappyData 系统用事务引擎 GemFire 进行联机事务处理, 而用 Spark 进行联机分析处理。也有一些现代应用程序利用键值存储系统, 如用 HBase 和 Cassandra 来存储实时操作型数据, 以进行快速更新操作; 而用 SQL-on-Hadoop 系统来处理分析型数据, 完成大规模分析型查询。

以上介绍的几种解决方案都只能说在某种程度上实现了针对混合事务分析处理的支持。当事务型和分析型请求被分别发送到系统中时, 现有的解决方案确实提供了一个较合适的平台来支持它们, 然而还没有一个解决方案能够真正支持在同一个事务中高效地既处理事务请求也处理分析请求。为了全面支持混合事务分析处理, 系统应允许不仅在接收或更新数据的事务提交后再进行分析, 而且能将分析作为事务请求的一部分进行提交, 从而完成对最新数据的分析。

此外,当前大多数混合事务分析处理解决方案使用多个组件来提供所有需要的功能,而这些不同的组件通常由不同的人群维护。因此,如何保持这些组件的兼容性并为最终用户提供单一的系统界面是一项具有挑战性的任务。

16.4 大数据时代的新型数据仓库

随着大数据时代的来临,数据仓库对于企业决策的支持作用越来越大。由此,数据仓库也成为各大厂商看重并着力发展的业务领域。IBM、Oracle、Teradata 等厂商纷纷采用各种软硬件技术(如大规模并行处理、列存储等),将其产品扩展到 PB 级数据量。另外,新兴的互联网企业也在尝试利用一些新技术(如 MapReduce)开发能支持大规模非结构化数据处理的数据仓库解决方案,如 Facebook 在 Hadoop 基础上开发出 Hive 系统,用来分析点击流和日志文件。

1. 系统需求的变化

和传统的数据仓库相比,大数据时代数据仓库系统面临的需求发生了如下一些变化。

(1) 数据规模急增

数据仓库中的数据量由 TB 级升至 PB 乃至 ZB 级,并仍在持续爆炸式增长。互联网数据中心(IDC)发布的数据显示,2016 年全球数据存量达 16 ZB,2020 年达到 44 ZB,2025 年将高达 160 ZB。

(2) 数据类型多样

除了结构化数据之外,大数据时代的数据仓库还必须能够处理大量的半结构化和非结构化数据。数据类型的多样化源于媒介类型的极大丰富。社交网站、在线视频、数码摄像、移动通信、电子商务、遥感卫星等,每天都在源源不断地产生着各种各样的数据。

(3) 决策分析复杂

大数据时代,决策分析逐渐由常规分析转向深度分析。数据分析日益成为企业利润必不可少的支撑点。根据 TDWI(The Data Warehousing Institute)对大数据分析的报告,企业已不满足于对现有数据的分析和监测,更期望能对未来趋势有更多的分析和预测,以增强企业竞争力。这些分析操作包括诸如移动平均线分析、数据关联关系分析、回归分析、what-if 分析等复杂统计分析,统称为深度分析。

(4) 负载种类混合

前面提到,数据仓库的创建将操作型处理和分析型处理区分开来。但随着当代数据分析业务对实时性的要求越来越高,事务型处理和分析型处理之间的界限开始逐渐变得模糊。一些大规模实时分析应用,如实时定价、新闻推荐、风险控制等,对混合类型负载(HTAP)进行支持的需求越来越旺盛。这类应用希望系统既能支持分析型处理负载,也能同时支持事务型处理负载,同时为了提高系统性能,需要系统能根据负载的特征进行有针对性的动态存储优化。

(5) 底层硬件变化

近年来新硬件技术的发展使计算机处理能力得以提升,多核处理器和众核处理器提供了强