

并发执行。

2. 恢复机制

由于 DRAM 内存的脆弱性和易失性，内存数据库中的数据容易被破坏和丢失，所以内存数据库数据需要在磁盘等非易失性存储介质中进行备份，并且在对数据更新时将日志写到非易失性存储介质中。

在内存数据库中，如果在事务提交时将日志写入磁盘，则由于写日志所产生的磁盘 I/O 会延长事务的处理时间，降低内存数据库的性能。所以，将日志写在何处以及何时将日志写入磁盘，在内存数据库中是一个非常重要的问题。一些研究者提出了预提交、组提交等方法来降低日志 I/O 的代价，并提出使用 PCM、flash memory 等非易失性内存存储日志的方法。首先将日志存储在非易失性内存中，然后提交事务，再异步地把日志写入磁盘。内存数据库的索引构建非常快，一些内存数据库并不记录索引更新的 redo 日志，而将 undo 日志保存在内存中，系统恢复时直接重建索引结构。一些内存数据库通过只记 redo 日志的方式降低日志代价，通过周期性的检查点技术保证未提交事务数据不写入磁盘，在系统恢复时加载检查点并重做 redo 日志。也可以通过记录的多版本机制消除记录的原地更新(in-place update)，未提交事务的记录版本最终被垃圾清理进程清除。

在发生系统崩溃时，如何从备份和日志中恢复数据也是内存数据库重要的性能指标。为了能够尽快地恢复系统的使用，一般可通过两步来恢复数据：首先恢复热点数据，即执行事务所必需的数据，然后在后台恢复其他非热点数据。另外，也可根据数据在磁盘上的存储顺序、优先级(是否为热点数据)以及访问频率等参数来确定数据的装载顺序。为了提高内存数据库的恢复性能，一些内存数据库采用了多核并行恢复技术，该技术需要将数据和日志进行分区，以保证分区的日志仅与分区的数据相关，每个核心可以并行地执行相应数据与日志上的恢复任务。

17.4 内存数据库的几种实现方案

针对不同的应用目标，内存数据库有不同的实现方案。本节介绍三种主要的方案：混合的内存加速引擎、独立的内存数据库系统和 GPU 数据库。

17.4.1 混合的内存加速引擎

这种方案是在传统数据库的磁盘处理引擎基础上，通过集成内存数据处理引擎技术来提升数据库的实时处理能力。当前的发展趋势是混合双/多引擎结构数据库，图 17.8 为几种产品示例。

图 17.8(a)为 Oracle 公司推出的支持两种存储格式的内存数据库产品 Oracle Database In-Memory，其行存储结构用于加速内存联机事务处理负载、列存储结构用于加速内存联机分析处理负载。列存储引擎是完全内存列存储结构，应用 SIMD、向量化处理、数据压缩、存储索


引等内存优化技术,并可以扩展到 RAC 集群提供 Scale-Out 能力和高可用性。

图 17.8(b)为 IBM 公司推出的面向商业智能查询负载的加速引擎 IBM BLU Acceleration。它采用内存列存储和改进的数据压缩技术、面向硬件特性的并行查询优化等技术加速分析处理性能。BLU Acceleration 与 DB2 构成双引擎,传统数据库引擎采用磁盘行存储表结构,提供事务处理能力;BLU Acceleration 引擎面向列存储,提供高性能分析处理能力。


图 17.8(c)为 Microsoft 公司的 SQL Server 产品结构。SQL Server 在传统磁盘行存储引擎的基础上增加了 Hekaton 内存行存储引擎,以加速联机事务处理性能;还增加了列存储索引,以加速联机分析处理性能。列存储索引可用于内存基本表,支持 B+树索引及数据同步更新,通过 SIMD 优化及批量处理技术提高查询性能。SQL Server 2019 CTP 2.1 支持基于 Intel Optane DC PMEM 非易失性内存的 Hybrid Buffer Pool 技术,通过直接对非易失性内存中数据的访问,消除数据从磁盘向 DRAM 缓冲区加载的代价。



(a) Oracle Database In-Memory



(b) IBM BLU Acceleration



(c) Microsoft SQL Server

图 17.8 混合双/多引擎结构数据库产品示例

随着大内存、多核处理器逐渐成为主流的计算平台,传统的关系数据库系统正经历着从磁盘数据库到内存数据库的升级。内存计算的高性能进一步提高了实时分析处理能力,推动了事务处理与分析处理的融合技术,提高了分析处理的数据实时性。

17.4.2 独立的内存数据库系统

这种方案对应独立设计的内存数据库系统,代表性的数据库系统包括 SAP HANA、Vector (VectorWise)、VoltDB 等。

SAP HANA 内存数据库是一个集成事务处理与分析处理负载于一体的高性能内存数据库系统。其列存储引擎通过面向多核处理器、SIMD 指令、Cache、数据压缩和大内存的优化技术最大化数据库内核的并行处理能力,事务处理引擎采用适合事务处理的存储结构,数据库支持在操作数据上同时执行事务处理与分析处理任务。HANA 通过列存储数据压缩技术提高内存利用率,事务处理数据则采用简单的数据压缩方式,通过主存储和 delta 列存储两种存储模型分别优化 OLTP 与 OLAP 负载。当前,有研究将 NVRAM 作为内存数据库的新型非易失性存储,利用其大容量、低成本、接近内存访问性能的特点进一步提高内存数据库的性价比,提高内存数据库在重启时的数据加载性能。

Vector(VectorWise)是荷兰 CWI 研究院在 MonetDB/X100 的基础上于 2008 年推出的商业化内存分析型数据库产品,通过与 INGRES 数据库结合,由 Action 公司于 2010 年推出 VectorWise 1.0 版本。该数据库的顶层采用 INGRES 架构,提供数据库管理、数据库连接、查询解析和基于代价的优化模型等功能,查询执行引擎和存储引擎采用 MonetDB/X100 模块,以列存储、CPU 效率高的轻量数据压缩、向量处理、多核并行处理等技术提高性能。在 VectorWise 1.0 分析数据库中具有 Hadoop 集成功能,由 Hadoop MapReduce 提供海量数据处理功能,并由 VectorWise 提供高性能大数据 SQL 引擎。

VoltDB 是一个基于 SN 架构,支持完全 ACID 特性的内存数据库。VoltDB 使用水平扩展技术增加 SN 集群中数据库的节点数量,将数据和数据上的处理相结合,分布在 CPU 核上作为虚拟节点。每个单线程分区作为一个自治的查询处理单元,消除并发控制代价。分区透明地在多个节点中进行分布,节点故障时自动由复制节点接替其处理任务。VoltDB 采用快照技术实现持久性,快照是数据库在一个时间点完整的数据库复制,保存在磁盘上。VoltDB 将事务处理作为编译的存储过程调用,查询被分配到节点控制器串行执行,通过基于 CPU 核的分区机制最大化并行事务处理能力,以满足高通量事务处理需求。

17.4.3 GPU 数据库

随着 GPU 处理器技术的发展,以 NVIDIA GPGPU 为代表的加速器集成了大量的计算核心,通过 GPU 的高并发线程提供强大的并行数据访问和计算能力。GPU 处理器技术的发展为提升数据库性能提供了硬件支持,GPU 既可以加速传统的磁盘数据库系统,也可以作为全新的内存数据库的加速引擎。

PG-Strom 是磁盘数据库 PostgreSQL 的 GPU 加速引擎,它通过 GPU 代码生成器为 SQL 查询任务创建 GPU 上的执行代码,通过 GPU 强大的并行处理能力加速查询处理。PG-Strom 支持查询中 SCAN、JOIN、GROUP BY 等操作在 GPU 端的执行,还支持 SSD-to-GPU 模式的 GPU

直接存储访问技术。

OmniSci (MapD) 是一个基于 GPU 和 CPU 混合架构的内存数据库, 包含内存数据库模式的 CPU 版本与加速模式的 GPU 版本。OmniSci 通过将用户查询编译为 CPU 和 GPU 上执行的机器码提高查询性能, 通过向量化查询执行和 GPU 代码优化技术提高查询执行性能。查询执行时, CPU 负责查询解析, 与 GPU 计算并行执行。

传统数据库的基础硬件假设正在发生变化, 非易失性内存成为大容量、低成本、高性能的新内存, 改变传统数据库面向易失性内存而设计的日志、缓存、恢复等机制; 硬件加速器成为高性能计算 (high performance computing, HPC) 的主流平台, 也将成为高性能数据库的计算平台, 面向 GPU 架构及 CPU-GPU 异构计算平台的数据库也成为一个新的技术发展趋势。

17.5 内存数据库前沿技术与展望

硬件技术的发展为内存数据库提供了硬件基础, 以 GPU、FPGA 为代表的异构计算体系结构的发展成为高性能计算平台的主流技术。

从存储技术的发展来看, 大内存已成为高性能计算的主流配置, 非易失性内存 NVRAM 已进入产品化阶段, 高性能多层堆叠 SSD 缩小了传统内存与外部存储之间的性能差距, RDMA、NVLink (GPU 架构) 等数据传输通信技术降低了网络访问延迟, 异构存储提供了基于性能、成本的不同组合方案。

传统的数据库基于同构硬件架构而设计。异构硬件架构需要数据库扩展对不同硬件的支持, 将数据库的存储引擎及查询引擎与异构硬件进行优化匹配, 为用户提供满足不同性能与成本需求的解决方案。

1. 面向千核处理器的内存数据库技术

随着 ARM 处理器成为 TOP 500 新型高性能计算平台, 基于 ARM 处理器的千核处理器计算平台成为新的高性能内存数据库硬件平台。与 X86 处理器相比, ARM 处理器的核心集成度更高, 基于多路处理器的千核计算平台为高性能内存数据库提供了更加强大的并行计算能力, 也需要数据库在千核并行处理技术上对传统的并发控制和查询处理进行优化, 以更好地发挥 ARM 处理器的并行计算能力。数据库传统的并发控制技术在千核处理器平台上不能自动适应, 更高的并发度甚至可能降低事务处理的整体性能, 需要根据千核处理器的硬件特征优化并行控制算法, 也需要对传统的并发控制算法进行深入评估, 确定最优并行度。另一方面, 千核处理器在分析处理负载中提供了更强大的并行计算能力, 但需要通过面向 NUMA 结构优化多核并行算法性能, 最大化千核并行计算性能。

2. 面向异构内存的内存数据库技术

NVRAM 的出现使内存成为持久存储设备, 补足了内存数据库在事务处理 ACID 特性中长期缺失的 D 特性, 从而使内存数据库成为真正意义上的完整数据库系统。NVRAM 具有内存的访问特性, 但其物理结构决定了它在内存访问延迟、带宽等性能上与 DRAM 存在差距, 在优